

MODELADO PREDICTIVO DEL ÍNDICE DE CALIDAD DEL AGUA EN LA CUENCA DEL RÍO BOGOTÁ: UN ENFOQUE BASADO EN MACHINE LEARNING Y ANÁLISIS DE METALES PESADOS

Jennifer Alejandra Casallas Torres

RESUMEN

La presente investigación desarrolla un marco estadístico y computacional para la estimación del Índice de Calidad del Agua (ICA) en la cuenca del río Bogotá, integrando modelos de aprendizaje automático y el análisis de concentraciones de metales pesados. Dada la complejidad no lineal de la contaminación hídrica, se evaluó el desempeño de algoritmos de aprendizaje supervisado, incluyendo *Random Forest*, *LightGBM*, *XGBoost*, *Support Vector Regression* (SVR) y *Elastic Net* como modelo de referencia estadística (*baseline*). La metodología incluyó el preprocesamiento de registros históricos (2005–2024) del Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM); estructurados en cuatro escenarios de modelamiento, el escenario 1 (S1) contempló la totalidad de 38 variables incluyendo los parámetros de la estructura normativa del ICA; el S2 con un total de 25 variables; el S3 evaluó la viabilidad operativa de una matriz mínima de 7 parámetros medibles *in-situ*, prescindiendo de 2 variables de laboratorio obligatorias en el cálculo del ICA-IDEAM; y el S4 configuró un entorno híbrido que integró a los 7 parámetros *in-situ*, la Demanda Bioquímica de Oxígeno y la matriz de 3 metales pesados (Aluminio, Cadmio y Cromo). Para mitigar la dependencia espacial y temporal de los datos, se implementó un enfoque de validación bloqueada espacio-temporal. El rendimiento de los modelos se evaluó utilizando métricas como MAE, RMSE, R^2 . Los resultados demostraron una alta precisión predictiva; en los escenarios parsimoniosos orientados a la optimización del monitoreo que son S3 (7 variables *in situ*) y S4 (7 variables *in situ* + 1 parámetro de laboratorio + 3 metales). El mejor rendimiento en la validación temporal fue el del modelo *LightGBM* tanto para S3 un $R^2 = 0,82$ y $RMSE = 0,0635$; como en S4 un $R^2 = 0,90$ y $RMSE = 0,0470$. Al evaluar la validación espacial el algoritmo *Random Forest* consolidó el mejor desempeño predictivo global, alcanzando un $R^2 = 0,75$ y $RMSE = 0,0314$ en el escenario S4. En cambio, en S3 el que obtuvo un mayor R^2 fue SVR de apenas 0,57. Finalmente, el uso de Inteligencia Artificial Explicable SHAP, permitió cuantificar la contribución de las variables a la predicción del ICA e identificar patrones de influencia. Los resultados buscan optimizar los esquemas de monitoreo, priorizando variables críticas y fortaleciendo la gestión del río basada en evidencia técnica interpretable.

Palabras clave: Aprendizaje Automático, Calidad del Agua, Metales Pesados, cuenca hidrográfica, índice de calidad de agua (ICA), análisis espacio temporal, IA Explicable (SHAP), Modelado Predictivo, parámetros fisicoquímicos.

INTRODUCCIÓN

La gestión de los recursos hídricos en cuencas de alta presión antrópica representa uno de los desafíos ambientales más críticos para la sostenibilidad en Colombia. El río Bogotá, como eje estratégico del desarrollo socioeconómico en el departamento de Cundinamarca, presenta un deterioro constante debido a vertimientos industriales y domésticos, particularmente en su cuenca alta (CAR, 2015). Si bien el IDEAM ha consolidado bases de datos robustas sobre parámetros físicoquímicos y microbiológicos, el análisis de esta información se ha limitado tradicionalmente a enfoques descriptivos y normativos. Estas metodologías convencionales, aunque necesarias para el cumplimiento legal, resultan insuficientes para capturar las dinámicas complejas, multivariadas y no lineales que caracterizan el comportamiento de los contaminantes en ecosistemas fluviales tan intervenidos.

Bajo este contexto, la presente investigación surge de la necesidad de transformar el seguimiento administrativo tradicional en una capacidad predictiva. Para ello, se propone convertir los datos históricos en una herramienta estratégica que permita anticipar la degradación del recurso hídrico mediante la aplicación de modelos de regresión apoyados en el *Machine Learning* para la estimación del índice de calidad del agua (ICA).

Metodológicamente, el estudio compara modelos supervisados (Elastic Net como baseline, SVR, XGBoost, Random Forest y LightGBM) para estimar el ICA, con el objetivo de identificar subconjuntos parsimoniosos de variables que reduzcan costos de monitoreo manteniendo un desempeño predictivo aceptable bajo validación fuera de muestra. Como componente diferenciador, se incorpora IA explicable mediante SHAP para interpretar la contribución de variables (incluyendo metales pesados) a la predicción del ICA, facilitando auditoría, priorización de intervenciones y soporte a decisiones de gestión ambiental basadas en datos.

1. PLANTEAMIENTO DEL PROBLEMA

La contaminación hídrica representa uno de los desafíos ambientales más críticos en Colombia, especialmente en cuencas con una densidad poblacional e industrial elevada como la del río Bogotá. En su tramo alto, a la altura del municipio de Villapinzón, convergen actividades industriales como las curtiembres, que históricamente han sido señaladas como fuentes significativas de vertimientos contaminantes (CAR, 2015). En respuesta a esta problemática, la Corporación Autónoma Regional de Cundinamarca (CAR) ha implementado medidas de control ambiental, incluyendo el cierre de establecimientos que incumplen la normatividad vigente desde 2021 (Semana Sostenible, 2021). No obstante, la efectividad de estas acciones de control depende directamente de la capacidad de interpretar y anticipar las dinámicas de calidad del agua, una tarea que requiere ir más allá del seguimiento administrativo para profundizar en el análisis de la información técnica disponible.

Bajo esta necesidad de monitoreo, el IDEAM ha consolidado de forma sistemática una base de datos sobre la calidad del agua en esta subzona hidrográfica desde el año 2005, incluyendo parámetros físico-químicos y microbiológicos como la Demanda Bioquímica de Oxígeno (DBO), Demanda Química de Oxígeno (DQO), Sólidos Suspendidos Totales (SST), nitrógeno, fósforo, coliformes, pH y temperatura. Sin embargo, estos datos han sido utilizados principalmente para análisis descriptivos o normativos, limitándose a comparar los valores observados con los límites permisibles establecidos por la legislación ambiental o para calcular índices; como el Índice de Calidad del Agua (ICA). Si bien estas herramientas son fundamentales para el cumplimiento legal, la naturaleza multivariada y potencialmente no lineal de los datos ambientales sugiere que existen relaciones complejas e interacciones que difícilmente se exploran mediante análisis descriptivos, comparaciones univariadas con umbrales o modelos lineales simples, motivando el uso de enfoques multivariados y métodos predictivos más flexibles.

Bajo este contexto, surge la oportunidad de integrar técnicas avanzadas que permitan maximizar el valor informativo de las series históricas. Los modelos de *Machine Learning (ML)*, por ejemplo, permiten identificar patrones complejos entre variables, estimar escenarios futuros y evaluar el impacto de intervenciones con mayor precisión que los enfoques descriptivos tradicionales. Su aplicación en el análisis de calidad del agua representa una innovación metodológica que puede fortalecer la toma de decisiones ambientales.

A pesar de la disponibilidad de datos históricos, no se han identificado estudios que apliquen de forma sistemática modelos de aprendizaje automático para predecir el ICA del río Bogotá bajo un esquema de validación que respete la dependencia espacio-temporal de los registros. Por ello, se considera importante desarrollar y evaluar un enfoque predictivo que permita estimar la calidad del agua a partir de variables fisicoquímicas y microbiológicas, incorporando modelos supervisados y técnicas de reducción de variables (regularización L1/L2, PCA).

Con base en lo anterior, el presente trabajo busca responder la siguiente pregunta de investigación:

¿En qué medida el uso y comparación de modelos supervisados (Random Forest, LightGBM, XGBoost, SVR) junto a Elastic Net (baseline) permite estimar el ICA del río Bogotá mediante un subconjunto parsimonioso de predictores, manteniendo interpretabilidad y desempeño predictivo bajo validación espacio-temporal, y aportando información útil para la priorización de la gestión ambiental?

2. JUSTIFICACIÓN

La calidad del agua en cuerpos hídricos como el río Bogotá se evalúa mediante parámetros físico-químicos y microbiológicos, cuyos valores deben cumplir con los límites establecidos en la normativa ambiental vigente, compilada en el Decreto Único Reglamentario del Sector Ambiente y Desarrollo Sostenible (Decreto 1076 de 2015) y en resoluciones específicas como la 0631 de

2015. El incumplimiento de estos valores puede generar afectaciones en los ecosistemas acuáticos, limitar el uso agrícola o recreativo del recurso, y representar riesgos para la salud pública.

Aunque entidades como el IDEAM y la CAR han desarrollado metodologías oficiales para calcular el Índice de Calidad del Agua (ICA) y publican boletines técnicos periódicos, estos análisis se han centrado en enfoques descriptivos y normativos. No se han identificado investigaciones enfocadas directamente sobre el río Bogotá donde apliquen modelos de aprendizaje automático para predecir el ICA. Esta ausencia metodológica representa una oportunidad para innovar en el análisis de calidad del agua mediante técnicas de ciencia de datos, las cuales serán finalidad de esta investigación.

Además, si bien el ICA es una herramienta útil para sintetizar múltiples parámetros en un solo indicador, su fórmula estándar puede presentar limitaciones para capturar la dinámica compleja de contaminantes específicos. Por ello, esta propuesta plantea el desarrollo de un modelo predictivo que no solo integre variables adicionales, sino que incorpore técnicas de interpretación avanzada como SHAP. El uso de estas herramientas permitirá establecer la contribución de las variables en relación con el cálculo del índice, identificando patrones y relaciones indirectas que los métodos tradicionales omiten. De este modo, la investigación busca transformar los datos históricos en una herramienta de gestión, fortaleciendo la toma de decisiones ambientales con base en evidencia técnica y explicable.

3. OBJETIVOS

3.1 Objetivo General

Desarrollar y validar un marco estadístico-computacional interpretable para la estimación del Índice de Calidad del Agua (ICA) del río Bogotá, mediante el diseño de escenarios parsimoniosos de variables físico-químicas y metales pesados, incorporando la variabilidad espacio-temporal.

3.2 Objetivos Específicos

- Realizar un análisis de componentes principales (PCA) y de correlación para identificar la estructura de interdependencia lineal entre las variables físico-químicas tradicionales y los metales pesados presentes en la base de datos, como técnica exploratoria.

- Reducir el conjunto de variables de monitoreo para lograr un modelo de predicción del ICA más parsimonioso, costo-efectivo e interpretable, mediante la identificación y eliminación de predictores redundantes o de bajo aporte mediante análisis exploratorio multivariado (correlaciones y PCA) y la comparación empírica de escenarios con diferentes subconjuntos de variables, empleando Elastic Net únicamente como modelo baseline de referencia (no como criterio de selección, dado su bajo desempeño predictivo), y verificando mediante validación bloqueada espacio-temporal que la reducción de variables conserva un desempeño equivalente al modelo.
- Evaluar y comparar el desempeño de algoritmos de aprendizaje supervisado (Random Forest, LightGBM, XGBoost y SVR) en la predicción del ICA continuo, utilizando la regresión ElasticNet como modelo de referencia.
- Validar la capacidad predictiva de los algoritmos mediante un enfoque de validación bloqueada espacio-temporal, cuantificando el desempeño con R^2 , RMSE, MAE, para estimar la capacidad de generalización en periodos no observados y entre estaciones de la cuenta del río Bogotá.
- Interpretar los determinantes de la calidad del agua mediante IA Explicable (SHAP), para cuantificar la contribución individual de cada variable química y metal pesado en la degradación del agua.

4. MARCO DE REFERENCIA

4.1. Marco Geográfico - Río Bogotá

Figura 1. Delimitación geográfica de la cuenta del río Bogotá



Fuente: Sanabria y otros (2017)

El río Bogotá nace en el Páramo de Guacheneque a 3.300 msnm y cubre 589.143 hectáreas, se divide en tres cuencas: alta, media y baja, atraviesa 47 municipios del departamento de Cundinamarca, lo que representa una influencia sobre algo más de 10 millones de personas, principalmente de Bogotá (CAR, 2020).

4.2 Normatividad

En Colombia, la regulación de la calidad del agua y los vertimientos se fundamenta en:

Decreto 1076 de 2015: Decreto Único Reglamentario del Sector Ambiente y Desarrollo Sostenible. Establece disposiciones para la prevención y control de la contaminación hídrica, el uso del recurso y los criterios técnicos para el manejo del agua.

Resolución 0631 de 2015: Define los límites máximos permisibles de contaminantes en vertimientos a cuerpos de agua superficiales y sistemas de alcantarillado, con diferenciación entre actividades domésticas e industriales (Ministerio de Ambiente y Desarrollo Sostenible, 2015).

4.3 Calidad del agua en Ecosistemas Fluviales

La calidad del agua se determina mediante variables físico-químicas y microbiológicas que reflejan su aptitud para distintos usos ambientales, domésticos, agrícolas. (Chapman, 1996)

Los ecosistemas hídricos se analizan considerando tres dimensiones:

a) Hidrodinámica

- Ríos: flujos unidireccionales (0.1–1 m/s), fuerte mezcla vertical.
- Lagos: corrientes lentas (0.001–0.01 m/s), posible estratificación.
- Aguas subterráneas: flujos estables, mezcla limitada.

b) Físico-química: Cada cuerpo de agua posee un patrón característico de propiedades físicas y químicas influenciado principalmente por el clima, la geología del terreno y la interacción agua-suelo.

c) Biológica: El componente biológico se refiere a los organismos que habitan el cuerpo de agua, como microalgas (fitoplancton), organismos adheridos a superficies (perifiton), plantas acuáticas, invertebrados y peces. La presencia y el desarrollo de estos organismos dependen de factores como la disponibilidad de nutrientes, la luz solar, la temperatura, el oxígeno disuelto y la dinámica del flujo.

4.4 Parámetros fisicoquímicos esenciales de calidad del agua

(Chapman, 1996)

4.4.1 Oxígeno disuelto (OD)

Indica la capacidad del agua para sostener vida acuática. Niveles bajos pueden reflejar contaminación orgánica o procesos de eutrofización.

4.4.2 pH

Mide la acidez o alcalinidad del agua. Valores extremos afectan la solubilidad de metales y la toxicidad para organismos acuáticos.

4.4.3 Conductividad eléctrica

Refleja la concentración de sales disueltas. Es un indicador indirecto de contaminación por vertimientos industriales o agrícolas.

4.4.4 Nitratos y fosfatos

Son nutrientes esenciales, pero en exceso provocan eutrofización, proliferación de algas y pérdida de oxígeno.

4.4.5 Contaminantes microbiológicos (coliformes fecales)

Indican contaminación por aguas residuales y riesgo sanitario para el consumo humano y el contacto recreativo.

4.4.6 Demanda Bioquímica de Oxígeno (DBO)

Mide la cantidad de oxígeno requerida por microorganismos para degradar la materia orgánica biodegradable en el agua.

4.4.7 Demanda Química de Oxígeno (DQO)

Cuantifica la cantidad total de sustancias oxidables (biodegradables y no biodegradables).

4.5 ICA

Es un indicador numérico que agrega múltiples variables físico-químicas y microbiológicas para sintetizar el estado del recurso hídrico en una sola cifra. Este índice permite, evaluar el estado del recurso hídrico, hacer seguimiento en el tiempo y facilitar la interpretación para la gestión ambiental, para calcular el ICA, según la metodología adoptada por el IDEAM véase sección 6.4.

Tabla 1.Calificación de la calidad del agua según los valores que tome el ICA

Categorías de valores que puede tomar el indicador	Calificación de la calidad del agua	Señal de alerta
0,00 – 0,25	Muy malo	Rojo
0,26 – 0,50	Malo	Naranja
0,51 – 0,70	Regular	Amarillo
0,71 – 0,90	Aceptable	Verde
0,91 – 1,00	Bueno	Azul

Nota. Adaptado de IDEAM (2025). La Tabla 1 presenta la clasificación del Índice de Calidad del Agua (ICA) según los rangos de valores obtenidos. Cada intervalo se asocia con una categoría cualitativa (muy malo, malo, regular, aceptable, bueno) que facilita la interpretación del estado del recurso hídrico. Los colores corresponden a la convención nacional utilizada por el IDEAM para comunicar resultados, sin constituir un estándar internacional.

4.6 Modelos de aprendizaje automático

El aprendizaje automático (Machine Learning (ML)) es una rama de la inteligencia artificial que permite que los sistemas informáticos aprendan patrones a partir de datos sin ser programados explícitamente para cada tarea. Arthur Samuel (1959) introdujo formalmente el término *Machine Learning* al describir la programación de computadoras digitales para comportarse de un modo que, de ser ejecutado por un ser humano, se consideraría un proceso de aprendizaje, lo definió como “la capacidad de las computadoras para aprender sin ser programadas de forma explícita”.

Elastic Net

Combina L1(Lasso) +L2 (Ridge), lo que permite un equilibrio entre reducción de coeficientes y selección de variables y es útil cuando las variables están correlacionadas.

Función de costo:

$$Loss = RSS + \alpha \left(\lambda \sum_{j=1}^n |\beta_j| + (1 - \lambda) \sum_{j=1}^n \beta_j^2 \right)$$

Donde:

RSS = suma de residuos al cuadrado (error de ajuste)

α parámetro de regularización global (controla la fuerza de la penalización)

λ controla el equilibrio entre L1 y L2

n número de predictores

β_j = coeficiente del predictor j

Ventaja: Es excelente para manejar la multicolinealidad (parámetros que miden casi lo mismo, como la Conductividad Eléctrica y los Sólidos Suspendidos Totales). Elastic Net selecciona automáticamente cuáles de estas variables aportan información real y apaga las redundantes.

Desventaja: Es un modelo lineal. La contaminación del Río Bogotá es un proceso altamente no lineal y complejo (interacciones químicas, vertimientos intermitentes). Al asumir relaciones en línea recta, Elastic Net pierde precisión frente a los árboles cuando la contaminación se vuelve extrema.

Random Forest

Es un algoritmo de aprendizaje supervisado de conjunto (*ensemble*) propuesto por Leo Breiman (2001), que opera mediante la construcción de una multitud de árboles de decisión descorrelacionados. Formalmente, se define como un clasificador o regresor compuesto por una colección de estimadores estructurados en árboles, representados por la siguiente expresión:

$$\{h(x, \theta_k), k = 1, \dots, B\}$$

Donde:

h: Representa la función de predicción de un árbol de decisión individual dentro del conjunto.

x: Es el vector de entrada o variables predictoras (en esta investigación corresponden a los parámetros físico-químicos del agua como pH, Oxígeno Disuelto, etc.).

θ_k : Es un vector aleatorio independiente e idénticamente distribuido (i.i.d.) que determina la aleatoriedad de cada árbol.

k: Es el índice que identifica a cada árbol individual dentro del bosque.

B: Representa el número total de árboles (el tamaño del bosque) que componen el modelo *ensemble*.

Una vez construido el conjunto de árboles, el modelo genera la predicción final para una observación x se obtiene mediante el promedio de las respuestas de los árboles (en regresión) o por voto mayoritario (en clasificación); matemáticamente, el estimador final del bosque se expresa como: (Hastie et al., 2017).

$$\check{f}_{rf}^B(x) = \frac{1}{B} \sum_{k=1}^B h(x; \theta_k)$$

Donde cada componente de la ecuación de agregación se define como:

$\hat{f}_{rf}^B(x)$ la estimación final del modelo para el vector de entrada. El símbolo denota que el resultado es un valor predicho basado en los B árboles entrenados.

$\sum_{k=1}^B$ el operador de sumatoria, que indica la adición de las respuestas individuales de todos los árboles del bosque, desde el primero ($k=1$) hasta el último (B).

$\frac{1}{B}$ el factor de normalización que permite obtener el promedio aritmético de las predicciones, lo cual es esencial para reducir la varianza global del modelo y mejorar la estabilidad de la respuesta frente a datos ruidosos.

Ventajas:

- Control de sobreajuste: La agregación de múltiples árboles garantiza que el error de generalización converja, evitando que el modelo se ajuste al ruido de los datos.
- Manejo de correlación: Es altamente efectivo con variables predictoras interdependientes (como pH y conductividad) gracias a la selección aleatoria de características en cada nodo.
- Alta precisión: Al reducir la varianza mediante el promedio de estimadores, ofrece resultados más estables y precisos que un árbol de decisión único.
- Al entrenar muchos árboles en paralelo usando subconjuntos de datos, es extremadamente robusto frente a los valores atípicos (*outliers*) causados por vertimientos industriales.

Desventajas:

- Baja interpretabilidad: Se comporta como un modelo de "caja negra", lo que dificulta la visualización directa de la lógica de decisión en comparación con un solo árbol.
- Costo computacional: Requiere mayor capacidad de memoria y tiempo de procesamiento, especialmente al incrementar el número de árboles.
- Al promediar las predicciones de muchos árboles, le cuesta extrapolar o predecir valores que están fuera del rango de lo que vio en el entrenamiento. Si el río sufre una crisis de contaminación histórica nunca antes vista (valores de ICA extremadamente bajos), Random Forest tenderá a suavizar la predicción hacia el promedio.

XGBoost

Se define como un sistema de aprendizaje automático escalable para el aumento de árboles y se utiliza para la clasificación y regresión propuesto por Chen y Guestrin (2016), este modelo no entrena todos los árboles de forma simultánea, sino que utiliza un modelo de conjunto aditivo. Para un conjunto de datos con n observaciones y m variables, la predicción final $\hat{y}_i$ para una observación x_i es la suma de las predicciones de K funciones de árbol independientes, expresada matemáticamente como:

$$\hat{y}_l = \phi(x_i) = \sum_{k=1}^K f_k(x_i), f_k \in F$$

Donde:

$\hat{y}_l$: es la predicción final acumulada para la observación i

k: es el índice o contador del árbol actual en la secuencia de optimización.

K: es el número máximo total de árboles de decisión (estimadores) construidos en el modelo.

F: Es el espacio de todos los árboles de regresión (CART).

$f_k(x_i)$: Corresponde a un árbol individual que asigna puntajes a las hojas.

Para garantizar la precisión y evitar el sobreajuste (overfitting), el modelo se entrena minimizando una función objetivo regularizada:

$$L(\phi) = \sum_i l(\hat{y}_i, y_i) + \sum_k \Omega(f_k)$$

Donde:

Función de pérdida (l): Mide la diferencia entre la predicción y el valor real.

Término de Regularización (Ω): Es la característica distintiva de XGBoost que penaliza la complejidad de los árboles, para suavizar los pesos finales y evitar el sobreajuste, definida como:

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda ||w||^2$$

En esta expresión, T representa el número de hojas en el árbol y w corresponde a los puntajes o pesos asignados a dichas hojas. De acuerdo con los autores, cuando el parámetro de regularización se establece en cero, la función objetivo retorna al impulso de árboles de gradiente método tradicional.

Ventajas:

- Control de sobreajuste en dinámicas ambientales complejas: XGBoost incluye una regularización matemática nativa (γ y λ) que castiga los árboles demasiado complejos. En el contexto del Río Bogotá, esto evita que el modelo "se aprenda de memoria" el ruido o

anomalías atípicas de una sola estación y, en su lugar, aprenda el patrón general de contaminación de la cuenca, mejorando su capacidad de generalización temporal (años no observados).

- Manejo eficiente de la realidad institucional (datos dispersos y faltantes): El modelo propone un algoritmo novedoso que encuentra de forma automática la mejor ruta de división para los valores ausentes. Esto es una ventaja crítica para nuestro problema, ya que las bases de datos históricas del IDEAM sufren de vacíos debido a fallas logísticas o falta de reactivos en los laboratorios; XGBoost permite predecir el ICA de forma continua sin necesidad de descartar registros valiosos.

Desventajas:

- Presenta una alta dependencia de la configuración de hiperparámetros (tasa de aprendizaje, profundidad máxima y coeficientes de regularización). Para nuestro problema, un ajuste incorrecto puede causar que el modelo ignore el impacto de variables con menor frecuencia, pero alta toxicidad (como los metales) o que falle drásticamente al intentar generalizar espacialmente en estaciones críticas como Puente La Virgen.
- Requiere un entrenamiento secuencial y un costo computacional y de memoria mucho más elevado que los modelos lineales tradicionales. Aunque para el análisis histórico esto no es restrictivo, si se desea implementar el modelo en dispositivos periféricos de bajo costo o sondas automáticas para alertas en tiempo real (como se plantea en el Escenario S3), la demanda de recursos de XGBoost representa una limitación técnica frente a arquitecturas más ligeras como LightGBM.

LightGBM

Desarrollado por Microsoft, es un algoritmo de aprendizaje automático de alta eficiencia que mejora las limitaciones de velocidad de otros métodos de aumento de gradiente como XGBoost. Está diseñado para manejar grandes volúmenes de datos con un uso optimizado de memoria, LightGBM utiliza un crecimiento por hojas (leaf-wise) lo que significa que expande la hoja que reduce más la pérdida (error), lo que permite una mayor precisión y una convergencia más rápida (Ke et al., 2017).

Para optimizar el entrenamiento, emplea la técnica GOSS (Gradient-based One-Side Sampling), la cual utiliza un multiplicador para compensar el sesgo del muestreo:

$$\frac{1 - a}{b}$$

Este factor permite estimar la ganancia de información de manera precisa utilizando solo una fracción del conjunto de datos, donde:

a= Es la fracción de los datos que tienen los gradientes más grandes. Representa el porcentaje de instancias con mayor error.

b= Es la fracción que se toma aleatoriamente del resto de los datos, los que tienen gradientes pequeños o ya están bien aprendidos.

Ventajas:

- Es un algoritmo significativamente más rápido que el Boosting tradicional, lo que facilita la ejecución eficiente de iteraciones en la optimización de hiperparámetros y la validación cruzada espacio-temporal de los escenarios hídricos.
- Al crecer por hojas (leaf-wise) con división guiada por el gradiente, logra identificar patrones no lineales altamente específicos en la contaminación del río (como picos súbitos de vertimientos industriales), superando la rigidez de los árboles convencionales.

Desventajas:

- Gran cantidad de hiperparámetros fundamentales (tasa de aprendizaje, número de hojas, regularizaciones), lo que exige un proceso de calibración riguroso para encontrar la combinación óptima.
- Debido a su alta flexibilidad matemática y su crecimiento por hojas, el modelo tiende a memorizar el ruido cuando se trabaja con datasets pequeños (inferiores a 10,000 registros), como es el caso de nuestra base de datos de 474 registros. Además, su alta flexibilidad requiere una validación espacio-temporal estricta para garantizar que el algoritmo no se confunda con los cambios estacionales. Este riesgo teórico se mitigó de forma estricta limitando la profundidad máxima de los árboles (`max_depth`), exigiendo un número mínimo de datos por hoja (`min_child_samples`) para evitar que el algoritmo aisle registros individuales; y `Reg_Lambda` para la penalización L2, evaluando el desempeño mediante un esquema de validación cruzada espacio-temporal bloqueada propuesto en esta investigación.

SVR

De acuerdo con Géron (2019), la Regresión de Vectores de Soporte (SVR) consiste en invertir el objetivo de la clasificación tradicional mediante máquinas de soporte vectorial. Mientras que en clasificación el propósito es maximizar el ancho de la calle (*street*) entre clases limitando sus violaciones, en SVR el objetivo es albergar la mayor cantidad posible de observaciones dentro

de dicha calle, restringiendo al mismo tiempo las violaciones de margen (es decir, las instancias que quedan fuera del canal).

El ancho de esta calle o canal de tolerancia es controlado por el hiperparámetro ϵ (épsilon). El modelo se considera ϵ –insensible, debido a que la inclusión de nuevos datos de entrenamiento dentro de la banda o canal no altera las predicciones finales; el modelo solo se ve afectado por las instancias que determinan los límites o quedan fuera de él. Para un modelo lineal, la función de predicción se expresa matemáticamente en el texto como:

$$\hat{y} = w^T x + b$$

Donde:

$\hat{y}$: es el valor estimado o predicho

w : es el vector de pesos de las variables predictoras.

x : es el vector de variables de entrada (parámetros fisicoquímicos).

b : es el término de sesgo (bias).

Adicionalmente, el comportamiento y la flexibilidad del canal se regulan mediante el hiperparámetro C . Un valor pequeño de C permite una mayor tolerancia a las violaciones de margen (puntos fuera de la calle), actuando como un freno de regularización que suaviza el modelo, mientras que un valor grande de C penaliza estrictamente las desviaciones, ajustando el modelo con mayor rigidez a los datos de entrenamiento. Finalmente, para abordar las relaciones complejas y no lineales de la contaminación hídrica, el algoritmo implementa de forma nativa el truco del Kernel (*Kernel trick*), permitiendo extender esta misma lógica lineal hacia fronteras curvas y flexibles no lineales (Géron, 2019).

Ventajas:

- Mantiene buena capacidad predictiva aun con tamaños de muestra moderados, lo que lo hace útil en cuencas con baja frecuencia de muestreo.
- Variables como pH, oxígeno disuelto, turbidez y temperatura interactúan de manera compleja. Los kernels del SVR permiten modelar estas relaciones sin necesidad de transformaciones manuales, lo que mejora la predicción del ICA frente a métodos lineales tradicionales.
- Los datos de campo suelen tener variabilidad natural y errores de medición. El margen de tolerancia del SVR ayuda a suavizar el impacto de estas inconsistencias.

Desventajas:

- La elección del kernel y de parámetros como C y ϵ ($C, \text{gamma}, \text{epsilon}$) es crítica, una mala configuración puede producir un modelo que ignore la variabilidad natural de los ríos o que sobreajuste a un conjunto reducido de datos.
- Requiere mayor memoria y tiempo de procesamiento durante la etapa de entrenamiento y validación cruzada en comparación con los modelos lineales simples.
- Registros extremos (ej. descargas puntuales de contaminantes, errores de laboratorio) pueden alterar el hiperplano y degradar la predicción del ICA si no se aplican técnicas de limpieza o robustecimiento.

SHAP

Basado en la teoría de juegos cooperativos de Shapley (1952) y adaptado al aprendizaje automático por Lundberg y Lee (2017), es una herramienta de IA Explicable que permite descomponer la predicción de cualquier modelo para cuantificar la contribución exacta de cada variable (ejemplo de esta investigación el pH, DBO, Metales pesados) en el resultado final. Este método garantiza la consistencia y la aditividad. Matemáticamente, SHAP define una explicación como un modelo sustituto lineal de variables binarias, para una predicción específica, el método define la función de explicación g como:

$$g(z') = \phi_0 + \sum_{i=1}^M \phi_i z'_i$$

Donde:

$g(z')$: Es el modelo de explicación.

ϕ_0 : Es el valor base (la predicción promedio de todos los datos de entrenamiento).

ϕ_i : Es el valor SHAP para la variable i (la contribución de esa variable).

M : Es el número total de variables de entrada.

Ventaja: Se puede aplicar matemáticamente sobre cualquier algoritmo predictivo que elijas (como LightGBM o SVR), lo que te permite comparar la importancia y el comportamiento de las variables fisicoquímicas entre distintos modelos bajo una misma métrica común.

Desventaja: Para un dataset con múltiples parámetros fisicoquímicos, el tiempo de procesamiento crece de forma exponencial, lo que exige el uso de aproximaciones computacionales (como TreeSHAP o KernelSHAP) que pueden demandar alta memoria en fases de validación.

4.7 Métricas de desempeño

Para la validación de la estimación continua del ICA:

R² (Coeficiente de Determinación): Significa la proporción de varianza en los datos observados que puede explicarse por las variables independientes.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Donde:

y_i : valor observado

$\hat{y}_i$: valor estimado por el modelo

$\bar{y}$: promedio de los valores observados

RMSE (Raíz del Error Cuadrático Medio): Se expresa en las mismas unidades que los valores observados y predichos, lo que facilita la interpretación de la magnitud del error (Willmott 1982). Matemáticamente, se calcula mediante la siguiente expresión:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Donde:

y_i : valor observado.

$\hat{y}_i$: valor estimado por el modelo.

n : número total de observaciones.

MAE (Error Absoluto Medio): Indica, en promedio, cuánto se alejan las predicciones del modelo de los valores reales.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

5. ESTADO DEL ARTE

En la última década, la modelación de la calidad del agua mediante aprendizaje automático (*Machine Learning, ML*) se ha consolidado como una línea de investigación activa, impulsada por el incremento en la disponibilidad de series históricas de monitoreo y por la necesidad de metodologías capaces de capturar no linealidades, interacciones y heterogeneidad espacial en sistemas hídricos. En este marco, los índices sintéticos como el Índice de Calidad del Agua (ICA) han sido ampliamente utilizados como variables objetivo por su capacidad de resumir múltiples parámetros físico-químicos y microbiológicos en un único indicador operativo para la gestión ambiental. Sin embargo, la literatura muestra que el tránsito desde análisis descriptivos/normativos hacia enfoques predictivos y explicables sigue siendo desigual según el contexto geográfico y el tipo de cuerpo hídrico.

En Colombia, la aplicación de ML para estimar o predecir directamente el ICA ha sido limitada y según la evidencia revisada, no se identifican publicaciones que formulen explícitamente un esquema predictivo del ICA a partir de ML; no obstante, sí existen antecedentes relevantes que modelan variables individuales o índices relacionados. Sánchez (2025) implementó *Random Forest* y *XGBoost* para predecir el valor del Índice de Riesgo de Calidad del Agua (IRCA). Por su parte, Castañeda (2020) exploró la predicción continua de parámetros físicoquímicos individuales (oxígeno disuelto, conductividad, pH y temperatura) en el canal del Eje Ambiental de Bogotá, mediante la implementación de algoritmos de ensamble *Random Forest* y *XGBoost*, su enfoque metodológico estructuró cuatro escenarios de predicción espacio-temporal combinando los datos *in-situ* con variables exógenas de precipitación no obstante, los modelos resultantes no exhibieron suficiente poder predictivo y manifestaron problemas severos de sobreajuste (*overfitting*) y alta varianza, fallando en la captura de las fluctuaciones extremas del sistema hídrico. El autor concluyó que el desempeño deficiente estuvo directamente ligado a la limitación en el volumen de la data (reducida a 242 muestras), a la irregularidad en la frecuencia del muestreo y a factores disruptivos intrínsecos del cuerpo de agua, tales como la fragmentación física y el estancamiento del flujo en el canal. En contraste, Caicedo y Pérez (2021) plantearon una formulación del ICA para el río Bogotá (2010–2020) mediante métodos estadísticos descriptivos para evaluar el comportamiento histórico de la cuenca. Estos trabajos sugieren una base metodológica incipiente en modelamiento predictivo, aunque persiste una brecha específica: la ausencia de marcos que integren aprendizaje supervisado para la predicción del ICA como valor continuo en series históricas extendidas, con validación espacio-temporal y enfoques de interpretabilidad.

La literatura internacional evidencia un avance más sistemático, particularmente en el uso de modelos basados en árboles y ensambles. Una aplicación fue la de Basha et al. (2024) evaluaron *Random Forest*, *Naive Bayes*, *XGBoost* y *KNN* para estimar el ICA del río Shkumbini con nueve parámetros; los resultados favorecieron a *XGBoost* con R^2 98,61% y RMSE = 2,1, además identificaron que la demanda bioquímica de oxígeno (DBO), bicarbonato (HCO_3) y

fósforo total como predictoras dominantes. En Pakistán, Aldrees et al. (2022) mostraron que estrategias tipo *Bagging* y *Boosting* incrementan la fiabilidad predictiva al pasar de modelos simples a *Random Forest*, con precisiones de 0,96, reforzando la utilidad de modelos colectivos frente a individuales incluyendo metales pesados como magnesio (Mg), sodio (Na), calcio (Ca). De manera análoga, Elmotawakkil et al. (2025) evaluaron algoritmos de aprendizaje automático para predecir el ICA como *LSTM* que pertenece a la familia de las Redes Neuronales Recurrentes, *XGBoost*, árboles de decisión y *Random forest*; aplicados a un dataset proveniente de múltiples estaciones de monitoreo continuo, los autores identificaron a *LSTM* (en regresión) y *XGBoost* (en clasificación) como los modelos de rendimiento superior, con ocho variables de entrada, lo que refuerza el potencial de modelos parsimoniosos para apoyar la gestión hídrica.

En paralelo al incremento de desempeño, la literatura reciente enfatiza dos requisitos metodológicos adicionales: optimización robusta e interpretabilidad. Makumbura et al. (2024) tuvieron como objetivo evaluar y predecir la calidad del agua valor continuo, desarrollaron modelos ML como *RF*, *XGBoost* y *LightGBM* usando 8 parámetros; encontrando que *XGBoost* obtuvo el mejor rendimiento predictivo con R^2 de 0,99 en la etapa de entrenamiento y 0,992 en la etapa de validación, seguido de un desempeño competitivo por parte de *LightGBM* R^2 de 0,999 y *RF*. Asimismo, integraron un análisis de explicabilidad basada en SHAP, mostrando que la DQO y la DBO dominan la contribución global al *output* del modelo, aportando transparencia para toma de decisiones institucionales. En la misma línea, Choudhary et al. (2025) reportaron desempeños muy buenos para *CatBoost* y *Gradient Boosting* en ríos de la India, complementados con SHAP para validar consistencia en siete parámetros clave; y Ejaz et al. (2024) mostraron que una reducción de 19 a 7 variables entre ellas metales como Pb (Plomo), Hg (Mercurio), Cr (Cromo), Cd (Cadmio), Zn (Zinc) pueden sostener el rendimiento, consolidando a *Gradient Boosting* como herramienta efectiva para monitoreo de aguas superficiales. A este auge de arquitecturas basadas en árboles se suma el trabajo de Talukdar et al. (2024) incorporaron *LightGBM* y en la fase predictiva del valor ICA, determinaron que *Random Forest* supera en estabilidad general y capacidad de generalización a las redes neuronales profundas (DNN). Además, mediante la integración de gráficos de dependencia parcial (PDP) y un marco explicativo basado en SHAP, identificaron a la turbidez como el predictor crítico y transversal en la estimación del índice de calidad del agua.

No obstante, la comparabilidad de resultados depende críticamente de la naturaleza del sistema hídrico. Ahmad et al. (2024) utilizaron 12 modelos, entre los que incluyeron *RF*, *XGBoost*, *LightGBM*, *SVR*, *KNN*; y reportaron desempeños perfectos con regresión lineal en pozos subterráneos, atribuidos a estabilidad hidroquímica regional; concluyendo que modelos basados en árboles de decisión, como *ExT* y *GB*, modelaron eficazmente relaciones no lineales y lograron una alta precisión predictiva, pero, *AdaBoost*, *LightGBM*, y *SVR* presentaron tasas de error más altas y menor precisión predictiva. Este hallazgo subraya una distinción metodológica: la predictibilidad de acuíferos puede ser sustancialmente mayor que la de ríos superficiales, donde volatilidad hidrológica, aportes puntuales y variabilidad estacional incrementan la complejidad y

favorecen el uso de modelos no lineales de alta capacidad (ensambles y boosting). En consecuencia, para sistemas como el río Bogotá, resulta especialmente pertinente estudiar el desempeño bajo esquemas de validación que reconozcan dependencia espacio-temporal y condiciones cambiantes.

En conjunto, estos estudios sostienen dos tendencias: (i) los ensambles suelen dominar en desempeño predictivo en escenarios no lineales y (ii) la reducción controlada de variables puede ser viable sin pérdidas sustanciales de precisión en la predicción del ICA, lo cual es relevante para contextos donde el costo del monitoreo es una restricción.

Resultados consistentes se reportan en contextos hídricos heterogéneos, incluyendo agua subterránea. Zheng et al. (2024) evaluaron Árboles de Decisión, Random Forest y *XGBoost* para clasificación de calidad de agua subterránea en proximidad a un relleno sanitario, identificando a *XGBoost* como el modelo óptimo; ellos usaron metales pesados en la predicción y un aporte adicional fue la estimación de pesos de indicadores, donde pH, manganeso (Mn) y níquel (Ni) figuraron como variables influyentes. Lawal et al. (2024) evidenciaron que estrategias como *GridSearchCV* y *RandomizedSearchCV* son determinantes para el ajuste de hiperparámetros en modelos de *Gradient Boosting*, especialmente bajo desbalance de clases; ellos incluyeron metales como cadmio, cromo, plomo, arsénico y mercurio en la predicción y el mejor modelo individual fue *XGBoost* con rendimiento de 97,3%. Ho et al. (2019) propusieron un modelo de árboles de decisión para predecir clases del ICA en el río Klang (Malasia) y evaluaron escenarios de reducción de variables, destacando el interés por soluciones operativas con menor carga de monitoreo. Posteriormente, Hussein et al. (2023) compararon árboles de decisión, *SVM*, *K-NN* y Ensemble Trees utilizando 17 variables incluidos 2 metales y reportaron el mejor desempeño para *SVM* (93,33% de precisión).

Asimismo, se ha documentado la utilidad de enfoques híbridos y estrategias de preprocesamiento para mejorar robustez, Nguyen et al. (2025) demostraron la efectividad de los enfoques basados en ensambles híbridos y técnicas de IA Explicable mediante SHAP para reducir la incertidumbre en la clasificación de la calidad del agua. En su investigación, la combinación de modelos basados en árboles y redes neuronales deep learning alcanzó precisiones superiores al 99% en diferentes formulaciones del ICA. Ramya et al. (2024) compararon 14 clasificadores y concluyeron que Gradient Boosting supera 99% cuando se apoya en interpretabilidad local (LIME y SHAP), reforzando el criterio de auditabilidad. Zhong et al. (2025) mostraron que incorporar variables climáticas (precipitación y temperatura), además metales como el cadmio (Cd), cobre (Cu), cromo (Cr) y zinc (Zn), mejora el desempeño de ensambles. Zhou et al. (2022) propusieron un marco híbrido W-ARIMA-GRU acoplado con LightGB.

También, la elección de escenarios fijos de validación espacio-temporal se fundamenta en recomendaciones de la literatura. Oliveira et al. (2021) demostraron que, en tareas de predicción con datos espaciotemporales, los procedimientos de validación cruzada aleatoria tienden a

subestimar el error debido a la autocorrelación temporal y espacial. Su estudio concluye que bloquear los datos en espacio y/o tiempo es necesario para obtener estimaciones más realistas del desempeño, lo cual respalda el uso de esquemas fijos de validación temporal (train past, test future) y espacial. De manera complementaria, Tziachris et al. (2023) aplicaron validación espacial bloqueada en la predicción de salinidad de aguas subterráneas, mostrando que este enfoque mejora la capacidad de generalización frente a métodos aleatorios.

Finalmente, un componente transversal es el tratamiento de datos faltantes, habitual en series ambientales. La tendencia contemporánea favorece imputación múltiple mediante MICE con Predictive Mean Matching (PMM), ya que preserva mejor la distribución y la variabilidad del proceso que la eliminación de registros incompletos (Van Buuren, 2018). Este aspecto es especialmente relevante cuando el objetivo es entrenar modelos predictivos robustos sin distorsionar la señal ambiental.

Aunque los antecedentes internacionales (Ho et al., 2019; Hussein et al., 2023; Basha et al., 2024; Elmotawakkil et al., 2025) trabajaron con datos de múltiples estaciones y periodos, la validación aplicada fue convencional (train/test split, k-fold cross-validation); Oliveira et al. (2021) y Tziachris et al. (2023), dejan abierta la posibilidad de aplicar esquemas bloqueados espacio-temporales, como el implementado en este trabajo, lo cual representa un aporte metodológico adicional para garantizar robustez en escenarios con dependencia temporal y espacial.

En síntesis, la literatura internacional ha avanzado en predicción del ICA mediante ensambles, reducción de variables e interpretabilidad, pero persisten desafíos asociados a validación espacio-temporal, selección de métricas cuando el ICA se aborda como ordinal y adopción de procedimientos auditables en contextos institucionales. En Colombia, los estudios identificados se han enfocado en predicción de parámetros individuales o en formulaciones tradicionales del índice, lo que abre una oportunidad metodológica para el desarrollo de marcos predictivos del ICA con énfasis en parsimonia, explicabilidad e incorporación de variables como metales pesados en escenarios fluviales complejos como el río Bogotá.

6. METODOLOGÍA

6.1 Enfoque y diseño del estudio

El presente estudio se enmarca en un enfoque cuantitativo de tipo predictivo, orientado al desarrollo y validación de modelos de aprendizaje automático para la estimación del ICA en la cuenca del río Bogotá.

El diseño metodológico integra técnicas de análisis estadístico, exploración multivariada y modelamiento supervisado, considerando explícitamente la variabilidad espacio-temporal de los datos, se prioriza la interpretabilidad de los modelos y la identificación de un conjunto parsimonioso de variables, en concordancia con los objetivos del estudio.

6.2 Fuente de datos y unidad de análisis

Los datos utilizados corresponden a registros históricos provenientes del IDEAM, obtenidos a través del Sistema de Información del Recurso Hídrico (SIRH). La unidad de análisis corresponde a cada medición registrada por punto de monitoreo y fecha de muestreo.

La variable objetivo es el Índice de Calidad del Agua continuo (ICA).

La base de datos final presenta las siguientes características (véase Tabla 2)

Tabla 2. Características de la base de datos final

Característica	Valor
Número de registros	474
Número de variables	56 (inicial-77)
Puntos de monitoreo	11
Municipios	9
Periodo de estudio	2005–2024


Nota. Fuente propia. La tabla 2 incluye variables fisicoquímicas (pH, temperatura, conductividad, oxígeno disuelto), indicadores de carga orgánica (DBO5, DQO), nutrientes (nitrógeno y fósforo), sólidos suspendidos y metales pesados en agua y sedimento.

6.3 Preprocesamiento y depuración de datos

El preprocesamiento consistió en una secuencia de pasos orientados a garantizar la calidad y consistencia de los datos. Se inició con la limpieza de nombres y unidades de medida, seguida de la transformación de la base de datos de formato vertical a horizontal. Posteriormente, se eliminaron registros duplicados y se verificaron rangos válidos conforme a los lineamientos del IDEAM. Los valores faltantes se trataron mediante imputación múltiple (MICE) cuando la proporción de datos faltantes era moderada y la variable era relevante para el modelo; en casos de registros con ausencia total de información crítica se aplicó eliminación, y se homogenizaron las unidades de medida. Finalmente, se estandarizaron los formatos temporales y se construyeron variables derivadas (año y mes) para facilitar el análisis espacio-temporal.

La figura 2 describe las etapas del procedimiento de preprocesamiento.

Figura 2. Flujo de preprocesamiento y depuración de datos



Fuente: Elaboración propia

6.4 Cálculo del Índice de Calidad del Agua (ICA)

A partir de los valores observados para cada variable, se calculó el ICA siguiendo la metodología oficial del IDEAM, que incluye:

1. Transformación de cada parámetro mediante su curva funcional I_i .

Tabla 3. Fórmulas de indexación para cada parámetro Fisicoquímico

Parámetro Fisicoquímico	Ecuación
	Inicialmente se calcula el porcentaje de saturación de oxígeno disuelto PS_{OD}: $PS_{OD} = \frac{Ox * 100}{C_p}$ Donde Ox Es el oxígeno disuelto medido en campo (mg/l) CP: Es la concentración de equilibrio de oxígeno (mg/l), a la presión no estándar, es decir, oxígeno de saturación. Una vez calculado el porcentaje de saturación de oxígeno disuelto, el subíndice del oxígeno disuelto I_{OD} se calcula con la fórmula: $I_{OD} = 1 - (1 - 0,01 \cdot PS_{OD})$ Cuando el porcentaje de saturación de oxígeno disuelto es mayor al 100%: se calcula: $I_{OD} = 1 - (1 - 0,01 \cdot PS_{OD} - 1)$
Oxígeno disuelto (OD)	
Sólidos suspendidos totales (SST)	$I_{SST} = 1 - (-0,02 + 0,003 \cdot SST)$ Si $SST \leq 4,5$, entonces $I_{SST} = 1$ Si $SST \geq 320$, entonces $I_{SST} = 0$
Demanda química de oxígeno (DQO)	Si $DQO \leq 20$, entonces $I_{DQO} = 0,91$ Si $20 < DQO \leq 25$, entonces $I_{DQO} = 0,71$ Si $25 < DQO \leq 40$, entonces $I_{DQO} = 0,51$ Si $40 < DQO \leq 80$, entonces $I_{DQO} = 0,26$ Si $DQO > 80$, entonces $I_{DQO} = 0,125$
Conductividad eléctrica (C.E.)	$I_{C.E.} = 1 - 10 (-3,26 + 1,34 \log 10 C.E.)$ Cuando $I_{C.E.} < 0$, entonces $I_{C.E.} = 0$
pH	Si $pH < 4$, entonces $I_{pH} = 0,1$ Si $4 \leq pH \leq 7$, entonces $I_{pH} = 0,02628419 \cdot e^{(pH \cdot 0,520025)}$ Si $7 < pH \leq 8$, entonces $I_{pH} = 1$ Si $8 < pH \leq 11$, entonces $I_{pH} = 1 \cdot e^{[(pH-8) \cdot -5,187742]}$ Si $pH > 11$, entonces $I_{pH} = 0,1$

Nota. Adaptado de IDEAM (2025). La Tabla 3 presenta las fórmulas para calcular el subíndice de la variable de calidad del agua. Se construye una “relación funcional” o “curva funcional” (ecuación) adoptadas de las propuestas por Ramírez y Viña 1998 para oxígeno disuelto (OD), sólidos suspendidos totales (SST) y conductividad eléctrica (CE); la sugerida por la Universidad Politécnica de Cataluña en

2006, para demanda química de oxígeno (DQO) y la planteada por el laboratorio del Departamento de Calidad Ambiental de Oregón (Estados Unidos) para pH, IDEAM (2025).

2. Multiplicación del índice parcial por su peso w_i .

Tabla 4. Variables y ponderación para el cálculo del ICA- IDEAM

Variable	Unidad de Medida	Peso de importancia
Oxígeno Disuelto -OD	% Saturación	0,2
Sólidos Suspendidos Totales - SST	mg/L	0,2
Demanda Química de Oxígeno - DQO	mg/L	0,2
Conductividad Eléctrica - CE	uS/cm	0,2
pH	Unidades de pH	0,2

Nota. Adaptado de IDEAM (2025). La Tabla 4 presenta el peso relativo asignado a la variable de calidad.

3. Suma ponderada

$$ICA_j = \sum w_i * I_{ij}$$

Donde:

ICA_j Índice de Calidad del Agua calculado a la altura de un punto de monitoreo j.

w_i el ponderador o peso relativo asignado a la variable de calidad i.

I_i el valor calculado de la variable i, obtenido al ingresar el valor de la concentración de la variable obtenida en el punto de monitoreo j, en la curva funcional o ecuación correspondiente.

j Corresponde a la localización o estación de monitoreo específica donde se realiza la medición de las variables.


Este índice se utiliza como, variable dependiente en los modelos supervisados de regresión e indicador agregado para los análisis temporales y proyecciones.

Por tanto, el objetivo de los modelos no es replicar la fórmula del IDEAM, sino aproximar el ICA con parsimonia y extender su capacidad diagnóstica, identificando subconjuntos de variables que permitan reducir costos de monitoreo y, al mismo tiempo, incorporar contaminantes relevantes para la cuenca del río Bogotá.

6.5 Análisis exploratorio de datos (EDA)

Se realizó un análisis exploratorio con el fin de caracterizar la distribución de los datos y entender las relaciones entre variables. Este incluyó:

Figura 3. Flujo del análisis exploratorio de datos (EDA)



Fuente: Elaboración propia

La Figura 3 muestra el procedimiento de análisis exploratorio de datos realizado, se aplicaron técnicas univariadas (histogramas y boxplots), análisis espacial por estación, agregación temporal anual, matrices de correlación y análisis de componentes principales (PCA) con fines exploratorios de reducción de dimensionalidad. Este análisis permitió identificar patrones de heterogeneidad espacial, presencia de valores atípicos y relaciones no lineales.

6.6 Selección de variables

Las variables predictoras corresponden a los parámetros físico-químicos, metálicos y microbiológicos comúnmente utilizados en la evaluación de la calidad del agua en la cuenca. La selección de predictores para el desarrollo del marco computacional parsimonioso se estructuró bajo criterios teóricos basados en la química del agua y validación estadística multivariada, ejecutándose en tres fases secuenciales:

6.6.1 Evaluación de Regularización Lineal Penalizada

En primera instancia, se evaluó la aplicación del algoritmo Elastic Net como técnica de regularización simultánea (Lasso y Ridge) para la contracción de coeficientes y selección automática de variables. No obstante, las estimaciones del modelo bajo el escenario 1, determinaron que este enfoque lineal penalizado exhibió un desempeño predictivo deficiente, en validación espacial el R^2 durante el entrenamiento fue 0.26 y en pruebas -0.188, para la validación temporal en entrenamiento el R^2 fue de 0.1823 y en pruebas 0.553, Esta deficiencia predictiva es consecuencia directa de la incapacidad del supuesto lineal para capturar las interacciones complejas de la cuenca. Como se demuestra en el gráfico de coeficientes finales (véase anexos 12 y 13), En consecuencia, se descartó el uso de Elastic Net como método definitivo de selección, delegando la captura de las interacciones complejas directamente a los modelos basados en conjuntos de árboles (*boosting*).

6.6.2 Diagnóstico Multivariado mediante Análisis de Componentes Principales (PCA)

Ante las limitaciones del modelado lineal penalizado, se realizó un Análisis de Componentes Principales (PCA) clásico sobre el dataset del Escenario 1, el PCA fue una herramienta exploratoria, no se usaron directamente los componentes principales en el modelado. El examen detallado de la matriz de cargas (loadings) permitió diagnosticar dos fenómenos estructurales que justificaron la reducción de variables hacia el Escenario 2 (25 Parametros).

- Redundancia analítica por dependencia funcional en nutrientes: Se identificó un alto acoplamiento lineal en el primer componente principal (PC1), donde parámetros como el fósforo total (11.38) y el fósforo reactivo disuelto (6.59) cargaron simultáneamente con alta magnitud. Una dinámica idéntica se observó en la familia de los nutrientes nitrogenados, donde el nitrógeno total (7.37) y el nitrógeno amoniacal (7.98) compartieron el peso del PC1 junto al nitrógeno kjeldahl total (9.70). Al representar sub-fracciones químicas cuya variabilidad y masa ya se encuentran incorporadas de forma agregada dentro de los descriptores globales Nitrógeno Kjeldahl y Fósforo Total, su inclusión simultánea introduce una dependencia funcional estricta que satura la dimensionalidad de los modelos de aprendizaje supervisado, generando inestabilidad matemática innecesaria. Por tanto, se procedió a la exclusión de estas sub-fracciones bajo el principio de parsimonia.
- Independencia estructural de las fracciones metálicas: A diferencia de los nutrientes, la inspección del PCA reveló que los metales totales y sus correspondientes fracciones potencialmente biodisponibles describen ejes de varianza independientes. Por ejemplo, mientras el Cadmio Total registró sus mayores pesos en los componentes PC4 (13.26) y PC6 (14.23), el Cadmio Potencialmente Biodisponible se acopló a los componentes PC1 (2.33), PC2 (3.01) y PC7 (11.39). Esta separación matemática confirmó que ambas matrices responden a mecanismos de transporte y dinámicas fisicoquímicas diferenciadas en el río.

6.6.3 Criterio de Parsimonia variables del Escenario 2

A partir de la independencia estructural identificada en el PCA, la exclusión del nitrógeno total, nitrógeno amoniacal, fósforo reactivo, el año y los 9 metales potencialmente biodisponibles, se formuló como una hipótesis de optimización orientada a la gestión operativa y costo-efectividad del monitoreo ambiental. Dado que la determinación en laboratorio de las fracciones biodisponibles requiere técnicas complejas de especiación química que limitan su viabilidad analítica en redes de monitoreo continuo, se estructuró el Escenario 2 (S2) aislando dichos parámetros.

El propósito de este diseño fue evaluar si el conjunto de metales totales y las variables orgánicas remanentes tenían la capacidad estadística suficiente para codificar la degradación del Índice de Calidad del Agua (ICA). Esta hipótesis de selección se validó empíricamente en la fase de modelado supervisado con XGBoost y LightGBM, donde la remoción de las 13 variables redundantes descritas no generó degradación en las métricas de desempeño, sosteniendo un R^2 equivalente al de la línea base ($R^2 = 0,97$ en validación temporal y $0,93$ en validación espacial).

6.6.4 Criterio de Parsimonia variables del Escenario 3

Se seleccionaron las variables bajo restricción de gestión operativa de bajo costo. Este escenario reduce el espacio predictivo a variables medibles en campo mediante sensores rápidos y factores de contexto espacio-temporal (pH, temperatura, conductividad eléctrica, oxígeno disuelto, turbidez, mes de muestreo y elevación).

6.6.5 Criterio de Parsimonia variables del Escenario 4

Estructurado como un entorno predictivo intermedio para mitigar la pérdida de sensibilidad ante la contaminación industrial observada en S3. Sobre la arquitectura base de las variables in-situ, se reintrodujeron tres metales pesados totales (Aluminio, Cadmio y Cromo) y la demanda química de oxígeno (DQO).

La integración de estos tres metales específicos en el escenario S4 combinó el análisis exploratorio de las primeras componentes principales del PCA en S2 con criterios de relevancia hidroecológica validados en la literatura de la cuenca del Río Bogotá:

1. Aluminio Total (Al): Presenta una alta representatividad en las dinámicas de escorrentía y arrastre de sedimentos. Su comportamiento se caracterizó por concentrar su mayor carga y peso dominante en el eje del PC4 (25.20).
2. Cadmio Total (Cd): Indicador crítico de toxicidad persistente, asociado al uso difuso de fertilizantes agrícolas y descargas industriales específicas en la cuenca. Registró su peso

dominante y una contribución crítica en el PC4 (32.70), consolidándose como la variable de mayor relevancia en la definición de este componente.

3. Cromo Total (Cr): Definido como un contaminante prioritario y marcador antropogénico mandatorio dentro del área de estudio, dada la histórica influencia de la actividad industrial de curtiembres en sectores específicos del río. Este parámetro concentró su mayor peso y una contribución en el eje del PC2 (8.12).

6.7 Definición de escenarios de modelación

Con el fin de evaluar el impacto de la disponibilidad de información en el desempeño del modelo, se definieron cuatro escenarios. Véase tabla 5

Tabla 5. Definición de Escenarios de modelación

Escenario	N	Definición
S1 (completo)	38	Todos los parámetros disponibles
S2 (metales totales)	25	Configurado por un subconjunto de 25 variables. Este escenario prescinde de las fracciones de metales biodisponibles, del nitrógeno total, del nitrógeno amoniacal y del fósforo reactivo disuelto, con el fin de evaluar si las concentraciones de metales en su forma total y los parámetros globales de carga orgánica (tales como la DBO5, DQO y el Nitrógeno Kjeldahl Total) poseen la suficiencia predictiva necesaria para estimar el ICA. Además, no se tiene en cuenta la variable de contexto año para evitar que el modelo se apalanque en tendencias temporales puesto que ya se le esta dando el mes.
S3 (in situ + variables de contexto)	7	Incluye un subconjunto reducido de variables medibles en campo y contexto espacio-temporal (pH, temperatura, conductividad, oxígeno disuelto, turbidez, mes, elevación), prescindiendo de 2 variables de laboratorio obligatorias en el cálculo del ICA-IDEAM (DQO y SST).
S4(in situ + metales relevantes)	11	Las mismas 7 variables in-situ de S3 + DQO + 3 metales (Al, Cd, Cr).

Nota. Fuente propia. Estos escenarios permiten analizar el compromiso entre costo de monitoreo y capacidad predictiva, para el detalle de la selección de variables véase sección 6.6 y Anexo 9. listado de variables incluidas en cada escenario de modelado.

6.8 Modelos de aprendizaje automático

Se ajustaron modelos supervisados de regresión para estimar el ICA en escala continua a partir de un conjunto multivariado de predictores (parámetros fisicoquímicos, microbiológicos y metales). Se consideraron cinco modelos agrupados en tres familias con capacidades complementarias: (i) regresión lineal regularizada (Elastic Net), (ii) métodos de kernel (SVR), y (iii) ensambles basados en árboles (Random Forest, XGBoost y LightGBM).

Dado que varias covariables exhiben asimetría, valores atípicos y escalas heterogéneas, se incorporó escalado robusto (*RobustScaler*) a todo el conjunto de predictores antes del entrenamiento de los cinco modelos, para garantizar consistencia y comparabilidad en la evaluación. La prueba de Shapiro-Wilk aplicada a las 474 observaciones del conjunto mostró que todas las variables numéricas presentan p-valores <0.05 , rechazando la hipótesis de normalidad, (Véase anexo 4).

6.9 Entrenamiento y optimización de hiperparámetros

El entrenamiento de los modelos se realizó bajo un esquema de validación bloqueada, espacio-temporal, incorporando los pasos de preprocesamiento dentro del mismo flujo de entrenamiento para evitar fuga de información (*data leakage*). La optimización de hiperparámetros se llevó a cabo mediante búsqueda aleatoria (*Random Search*), seleccionada por su eficiencia en espacios de búsqueda amplios y por su buen desempeño empírico frente a métodos exhaustivos cuando el número de parámetros es elevado.

Durante el proceso de búsqueda, se utilizó validación cruzada interna con cinco folds (CV=5), lo que permitió estimar el desempeño de cada combinación de hiperparámetros y seleccionar aquella que maximizaba el coeficiente de determinación (R^2), este procedimiento se ejecutó exclusivamente dentro de los datos de entrenamiento de cada escenario, evitando fuga de información y garantizando que el modelo no utilizara registros externos al bloque correspondiente.

Una vez identificados los hiperparámetros óptimos, los modelos se entrenaron nuevamente y se evaluaron bajo los escenarios fijos de validación espacio-temporal descritos la sección 6.10.

Los hiperparámetros explorados incluyeron, de manera general:

- Número de estimadores
- Profundidad de árboles
- Tasa de aprendizaje

- Parámetros de regularización
- Parámetros del kernel en SVR

6.10 Evaluación y comparación del rendimiento

Para reducir el riesgo de data leakage (fuga de información) asociado a dependencia temporal y espacial, la evaluación del desempeño se realizó mediante dos esquemas de validación que respetan la estructura de los datos:

1. Validación temporal (train-past, test-future)

Se definió un escenario fijo en el cual los modelos se entrenaron con registros del 2005 a 2021 y como prueba los años 2022–2024. Este diseño reproduce un esquema de predicción futura, evitando que el modelo utilice información de años posteriores durante el entrenamiento. el conjunto de prueba representa ~14% del total, cubre tres años consecutivos y múltiples estaciones, lo que garantiza representatividad, independencia y cobertura temporal.

2. Validación espacial

Los modelos se entrenaron con 10 estaciones y se evaluaron en la estación rca_bogota_cun_cota_pte.la virgen [21208110], utilizada como prueba externa. Esta estación concentra sus registros en categorías críticas (Regular y Mala), lo que permite evaluar la capacidad de generalización hacia un perfil restringido y distinto al resto.

Aplicación en los escenarios de modelación (S1–S4)

Ambos esquemas de validación (temporal y espacial) se replicaron en los cuatro escenarios de modelación (S1–S4), aplicados de manera consistente a los cinco modelos supervisados considerados en este estudio (Elastic Net, Random Forest, XGBoost, LightGBM y SVR). De esta forma, cada escenario fue evaluado bajo las mismas particiones de datos, garantizando comparabilidad entre modelos y condiciones de prueba.

Aunque existen esquemas más exhaustivos como *rolling origin* o *leave-one-station-out* completo, en este estudio se optó por escenarios fijos debido a la heterogeneidad y limitaciones de la base de datos. Este diseño se reconoce como una simplificación metodológica, pero permite obtener métricas representativas y evaluar robustez bajo condiciones de extrapolación parcial. Se reconoce que usar una sola estación para la validación espacial limita la generalización de las conclusiones; sin embargo, se eligió la estación más crítica como caso de estrés para el modelo, lo cual se discute en la sección de Conclusiones.

6.11 Métricas de evaluación

El desempeño de los modelos se evaluó mediante:

- Coeficiente de determinación (R^2)
- Error cuadrático medio (RMSE)
- Error absoluto medio (MAE)

Estas métricas permiten evaluar de forma complementaria precisión, estabilidad del error y capacidad explicativa bajo los esquemas de validación definidos. Para comparabilidad entre los modelos se tuvo en cuenta principalmente el Coeficiente de determinación (R^2).

6.12 Interpretación de modelos

Con el fin de garantizar la interpretabilidad y transparencia de los resultados, se utilizó el método SHAP (SHapley Additive Explanations) únicamente en los modelos ganadores de cada escenario. SHAP permitió:

- Estimar importancia global de variables, identificando cuáles parámetros físicos-químicos, microbiológicos y metales tienen mayor peso en la predicción del ICA.
- Analizar contribuciones locales por observación, identificando patrones de influencia, posibles no linealidades y efectos de interacción entre variables.

Para los modelos basados en árboles se utilizó TreeSHAP, que permite calcular las contribuciones de manera eficiente aprovechando la estructura del ensamble. En contraste para SVR se empleó KernelSHAP, cuyo costo computacional es mayor debido al uso de aproximaciones basadas en muestreo.

Los resultados de SHAP se reportaron como soporte para la priorización de variables relevantes y para el diseño de estrategias de monitoreo parsimoniosas.

De forma complementaria se midió la ganancia en entrenamiento con la importancia de variables mediante la reducción de impureza (Mean Decrease in Impurity) basada en la estructura interna de cada modelo.

6.13 Consideraciones éticas

El estudio utiliza datos ambientales de acceso público y no involucra información personal ni datos sensibles. Se garantiza la trazabilidad del proceso analítico mediante documentación del preprocesamiento, parametrización de modelos y esquemas de validación. Asimismo, se promueve la reproducibilidad mediante fijación de semillas aleatorias cuando aplique y registro de configuraciones experimental

7. RESULTADOS

El análisis inició con la exploración de la base de datos, compuesta por 474 registros y 77 variables. Debido a la naturaleza técnica de la medición de parámetros hídricos, no todas las estaciones presentaban la misma frecuencia de reporte, por ende, se eliminaron las variables con más del 80% de datos faltantes a nivel global, garantizando un mínimo de representatividad estadística. Se reconoció que este criterio puede ocultar vacíos específicos por estación o periodo; para mitigar este riesgo, se aplicó la técnica de Imputación Múltiple por Ecuaciones Encadenadas (MICE), específicamente el método de Predictive Mean Matching (PMM), que incorporó como predictores la estación, el año y el mes de medición, y las demás covariables ambientales.

Este proceso resultó en la eliminación de 21 variables que no contaban con la representatividad estadística necesaria para el modelado, reduciendo la matriz a 474 registros y 56 parámetros, garantizando un dataset consistente para la ejecución de los escenarios S1 a S4.

Tabla 6. Estadísticos descriptivos de algunos parámetros principales

Parámetro	min	max	mean	median	Std
Solidos Suspendidos Totales_(mg/l)	2.250	8.828	211.924	56.000	570.205
Turbidez_(ntu)	1.000	6.890	589.955	52.500	1.453.406
pH_(unidades de ph)	5.520	10.950	7.218	7.155	0.610
Temperatura_(°c)	2.500	31.500	19.202	18.450	4.394
ICA	0.207	0.975	0.540	0.479	0.200
Conductividad eléctrica_(μs/cm)	12.050	1176.000	381.993	396.000	244.800
Demanda Bioquímica de Oxígeno	1.000	266.000	102.732	52.500	100.076
Oxígeno Disuelto (od)_(mg o2/l)	0.000	8.700	3.592	3.600	2.454


Nota. Fuente propia. A partir de datos procesados en Colab. La tabla presenta los valores mínimos, máximo, media, mediana y desviación estándar del conjunto de parámetros representativos de la calidad del agua, obtenidos a partir del dataset final. Estos estadísticos permiten caracterizar la distribución de los datos y evidenciar la variabilidad de los indicadores más relevantes para el modelado de escenarios S1 a S4; se evidencia que los parámetros de sólidos suspendidos, turbidez, conductividad y DBO5 presentan desviaciones estándar muy elevadas respecto a sus medias, lo que evidencia una alta variabilidad y episodios de contaminación. En contraste, el pH y la temperatura muestran valores más estables, mientras que el oxígeno disuelto refleja fluctuaciones moderadas, incluyendo registros anóxicos (0 mg/L).

Posteriormente, se realizó una caracterización estadística para evaluar la forma de la distribución y la dispersión de los datos. El cálculo de las medidas de tendencia central (media, mediana), dispersión (desviación estándar, coeficiente de variación) y de forma (curtosis y asimetría), (Véase anexo 5). En este análisis se identificó un valor extremo en el parámetro Cromo Potencialmente Biodisponible, un valor de 4,858 mg/kg registrado en abril de 2016 en la estación rca_bogota_cun_villapinzon_sanpedro-bogota, al contrastar este dato con el cromo total del mismo periodo, no se evidenció coherencia estadística ni ambiental, por lo que se consideró un dato atípico.

Dado que se trató de un valor atípico aislado, se aplicó una imputación puntual mediante la mediana histórica del mismo punto de monitoreo (37,2 mg/kg), reemplazando el valor extremo dataset de entrenamiento. Tras esta depuración, el valor máximo de cromo biodisponible en la base se redujo a 966 mg/kg, lo que permitió mantener la consistencia del conjunto de datos.

El dataset final estuvo conformado por 474 registros provenientes de 11 estaciones de la cuenca alta, media y baja del río Bogotá, y dado el tamaño limitado de la base y la finalidad predictiva del estudio, se usó la totalidad de los registros disponibles, sin aplicar criterios adicionales de inclusión/exclusión por estación. De esta manera, el modelo se entrenó sobre la información completa, buscando capturar las relaciones químicas generales de la cuenca en el periodo 2005–2024. (véase Figura 4)

Figura 4. Valor promedio del ICA histórico por estación de monitoreo




Fuente: Elaboración propia a partir de datos procesados en Colab

En la figura 4 se observa una marcada degradación de la calidad del agua a medida que el río avanza geográficamente, mientras que las estaciones de la cuenta alta como Villapinzón tienen

niveles de calidad Buena (0,907) (Véase Tabla 1), el índice desciende rápidamente hacia niveles de calidad aceptable, al recibir vertimientos de zonas industriales y residenciales, los puntos críticos como El Salto (0,371) y Campina LA (0,339) caen drásticamente a la categoría mala, evidenciando una incapacidad de autodepuración del río ante la carga contaminante acumulada.

Con el fin de obtener un panorama respecto a la evolución del ICA. (véase Figura 5)

Figura 5. Valor del ICA Promedio por Año periodo 2005-2024



Fuente: Elaboración propia a partir de datos procesados en Colab

La calidad del agua en la cuenca alta no presenta una tendencia de recuperación a largo plazo, manteniéndose estancada en niveles Regulares (promedio ~0,55). El periodo 2020-2022 muestra un descenso preocupante hacia la categoría Mala (0.44). Aunque la Empresa de Acueducto y Alcantarillado de Bogotá (EAAB), en 2020 reportó mejoras puntuales en la cuenca alta durante el confinamiento (Observatorio Ambiental de Bogotá, 2020), la CAR (2020) indico que, pese a la coyuntura de la pandemia, la cuenca seguía con problemas estructurales de vertimientos domésticos e industriales, y que los objetivos de calidad no se estaban cumpliendo. Esto indica que el efecto de la pandemia de COVID-19 fue localizado y temporal, sin traducirse en una recuperación sostenida de la calidad del agua, pues en 2021 se observa una leve recuperación, pero en 2022 el índice vuelve a caer. Aunque en 2023 y 2024 el ICA retorna a niveles regulares, el río permanece lejos de los estándares de un ecosistema saludable.

Antes del modelado, se aplicó el Análisis de Componentes Principales (PCA) y la matriz de correlación de Pearson como técnicas exploratorias para identificar redundancia de información.

Se calculó la correlación de Pearson (Véase Anexo 1), que mostró asociaciones moderadas y débiles entre la mayoría de las variables y el ICA. El PCA permitió observar cuánta varianza explicaban los grupos de variables en cada escenario, como criterio exploratorio de estructura, sin que ello implique directamente capacidad predictiva.

En S1 (38 variables), los primeros 13 componentes explicaron el 80% de la varianza, agrupando en familias de contaminación orgánica, metálica y temporal. En S2 (25 variables), al excluir los metales biodisponibles, se requirieron 10 componentes para explicar el 80% de la varianza, destacando hipótesis sobre la separación entre cargas orgánicas y metales industriales. En S3 (7 variables), tres componentes explicaron el 80% de la varianza, diferenciando clima/ubicación, contaminación directa y temporalidad. Finalmente, en S4 (11 variables), se combinaron mediciones in situ con metales relevantes, logrando una estructura de datos parsimoniosa para los modelos predictivos. (véase Anexo 9: listado de variables incluidas en cada escenario de modelado)

Evaluación del Desempeño de los Modelos Predictivos

Los modelos de aprendizaje automático se evaluaron bajo dos enfoques de validación: espacial y temporal, utilizando las métricas MAE, RMSE y R^2 . El ICA se encuentra en la escala [0,1], por lo que los errores reportados deben interpretarse en ese rango. Tras el análisis de los cuatro escenarios, se identificó que el rendimiento varió según la configuración de variables y el tipo de validación, destacando a los algoritmos basados en *boosting* (XGBoost y LightGBM) como los más consistentes en la predicción del ICA. (véase Tabla 7)

En el escenario S1, que integró la totalidad de las variables físico-químicas bajo validación espacial el modelo LightGBM alcanzó un R^2 de 0,91 y bajo validación temporal, XGBoost mostró robustez con un R^2 de 0,97.

En el escenario S2, se alcanzaron los valores más altos de R^2 . Bajo validación temporal, LightGBM obtuvo un R^2 de 0,97, con un promedio de R^2 en entrenamiento de $0,985 \pm 0,003$, lo que confirma una alta estabilidad entre folds. En validación espacial, XGBoost lideró con un R^2 de 0,93 y el promedio de R^2 en entrenamiento fue $0,98 \pm 0,007$, con baja dispersión entre folds. Este resultado demuestra que la eliminación de parámetros redundantes no solo simplificó el modelo, sino que redujo el ruido manteniendo un R^2 superior a 0,91 en ambas dimensiones de validación. Para mayor detalle de folds, (véase Tabla 8)

En el escenario S3, bajo validación espacial el SVR apenas alcanzó un R^2 de 0,513, con una variabilidad muy alta entre folds (valores entre 0.31 y 0.93), lo que reduce la confiabilidad del modelo. En contraste, bajo validación temporal, LightGBM mostró robustez con un R^2 de 0.8243

y un promedio en entrenamiento de 0.936 ± 0.013 , confirmando estabilidad y menor riesgo de sobreajuste.

Finalmente, el escenario S4 consolidó la viabilidad de un monitoreo optimizado. En validación temporal LightGBM obtuvo el mejor desempeño predictivo un R^2 de 0.9039 con un promedio en entrenamiento de 0.97 ± 0.004 y una baja varianza entre folds, lo que demuestra una alta estabilidad y confiabilidad. Mientras que en validación espacial Random Forest fue el de mejor desempeño con un R^2 de 0.7465, Sin embargo, el análisis desagregado por pliegues reveló una alta dispersión en el rendimiento con un valor mínimo de $R^2 = 0.3270$ y ajustes altos $R^2 = 0.9156$, con R^2 promedio de 0.59. Dado que el enfoque de validación bloqueada espacial aísla metodológicamente el efecto del sobreajuste (*overfitting*), esta fluctuación no responde a una deficiencia estructural del algoritmo, sino a la marcada heterogeneidad espacial de los datos hídricos en la cuenca. El modelo demuestra una alta capacidad de generalización en tramos con dinámicas físico-químicas estables, pero su transferencia geográfica se ve limitada en estaciones que presentan firmas de contaminación locales o atípicas respecto a la muestra de entrenamiento.

Así, para la validación temporal, S3 puede considerarse una alternativa de bajo costo para monitoreo básico, mientras que S4 representa el balance técnico ideal, combinando fidelidad predictiva con una carga analítica de laboratorio significativamente menor que el dataset original.

Tabla 7. Desempeño de los mejores modelos predictivos y R^2 promedio $\pm$ DE en entrenamiento, para los cuatro escenarios de estudio

Escenario	Enfoque	Mejor modelo	R^2	RMSE	MAE	RMSE relativo	R^2 promedio $\pm$ DE
S1	Espacial	LightGBM	0.9106	0.0187	0.0126	3.69%	0.984 ± 0.008
	Temporal	XGBoost	0.9717	0.0255	0.0163	5.23%	0.984 ± 0.004
S2	Espacial	XGBoost	0.9308	0.0164	0.0128	3.24%	0.987 ± 0.007
	Temporal	LightGBM	0.9734	0.0247	0.0173	5.07%	0.985 ± 0.003
S3	Espacial	SVR	0.513	0.044	0.0346	8.64%	0.628 ± 0.211
	Temporal	LightGBM	0.8243	0.0635	0.0481	12.55%	0.936 ± 0.013
S4	Espacial	Random Forest	0.7465	0.0314	0.0223	6.21%	0.598 ± 0.230
	Temporal	LightGBM	0.9039	0.0470	0.0344	9.29%	0.970 ± 0.004

Nota. Fuente propia. La tabla 7 presenta el desempeño de los modelos predictivos en cada escenario, evaluados bajo validación espacial y temporal. Se reportan los valores de R^2 , RMSE y MAE, junto con el RMSE relativo expresado en porcentaje, y el R^2 promedio $\pm$ DE.

Para detalle de folds en entrenamiento véase tabla.8.

Tabla 8. R^2 por fold en entrenamiento de los mejores modelos predictivos para los cuatro escenarios de estudio.

Escenario	Enfoque	Mejor modelo	R^2 por fold			
S1	Espacial	LightGBM	0.99042158 0.98916154	0.99329539	0.97685355	0.97230776
	Temporal	XGBoost	0.98650466 0.98820292	0.98558835	0.97755422	0.98203575
S2	Espacial	XGBoost	0.99038499 0.99132374	0.99356132	0.98349827	0.97448178
	Temporal	LightGBM	0.98448616 0.9858692	0.98911566	0.98098017	0.98501092
S3	Espacial	SVR	0.31027537 0.77115233	0.58519308	0.54091288	0.93212221
	Temporal	LightGBM	0.93395668 0.9502807	0.91266869	0.94630036	0.93610336
S4	Espacial	Random Forest	0.4177992 0.9156504	0.3270028	0.50938286	0.82068907
	Temporal	LightGBM	0.97447346 0.9745631	0.96530645	0.96493693	0.97049083


Nota. Fuente propia. La tabla presenta los valores de R^2 obtenidos en cada fold de entrenamiento para los modelos con mejor desempeño en los cuatro escenarios de estudio, bajo enfoques espacial y temporal.

En síntesis general, los resultados muestran que el desempeño de los modelos depende tanto del escenario como del enfoque de validación. En S2 se alcanzaron los valores más altos y estables de R^2 , confirmando la utilidad de un conjunto reducido de variables. En S3, el desempeño espacial fue inconsistente, pero bajo validación temporal LightGBM mostró robustez, lo que lo convierte en una alternativa de bajo costo para monitoreo básico. En S4, aunque Random Forest fue el mejor modelo en validación espacial, su alta variabilidad entre folds reduce la confiabilidad de ese resultado; en contraste, LightGBM bajo validación temporal alcanzó un R^2 de 0.90 con baja dispersión, consolidando a S4 como el balance técnico ideal: combina fidelidad predictiva con una

carga analítica de laboratorio significativamente menor que el dataset original.

La Figura 6 muestra la dispersión de los valores reales frente a los valores predichos del ICA en los escenarios S3 y S4; bajo validación temporal (entrenamiento 2005-2021 prueba 2022-2024), junto con la línea de identidad ($y = x$) que representa el ajuste perfecto.

Figura 6. Relación entre valores reales y predichos del ICA en los escenarios S3 y S4 bajo validación temporal



Fuente: Elaboración propia a partir de datos procesados en Colab


Se observa que, si bien ambos escenarios presentan una correlación elevada, el escenario S4 exhibe una menor dispersión de los puntos respecto a la línea de identidad. Esto indica un mejor ajuste del modelo en comparación con S3 y sugiere que la inclusión de metales clave en S4 permitió capturar con mayor precisión la variabilidad en los rangos críticos de calidad del agua, donde las mediciones in situ de S3 presentan limitaciones frente a contaminantes químicos específicos.

Además, para jerarquizar la influencia de los parámetros físico-químicos en la capacidad predictiva de los modelos, se analizó la importancia de variables mediante la reducción de impureza (MDI), que mide la ganancia en entrenamiento basada en la estructura interna del árbol (LightGBM), donde en regresión la impureza se define como el error cuadrático medio (MSE) o

la varianza. Las Figuras 7 y 8 detallan este comportamiento para los escenarios S3 y S4, respectivamente, calculado a partir de los modelos LightGBM que obtuvieron el mejor desempeño en cada escenario.

La Figura 7 muestra la jerarquía de importancia de los parámetros físico-químicos bajo el escenario S3, calculada mediante reducción de impureza (MDI) en el modelo LightGBM.

Figura 7. Importancia de variables S3, enfoque temporal mejor modelo LightGBM




Fuente: Elaboración propia a partir de datos procesados en Colab

Se observa que el modelo depende en gran medida de la Conductividad Eléctrica, Turbidez y el Oxígeno Disuelto, los cuales actúan como los principales divisores en la estructura de los árboles de decisión para segmentar la calidad del agua.

La Figura 8 muestra la jerarquía de importancia de los parámetros físico-químicos bajo el escenario S4, calculada mediante reducción de impureza (MDI) en el modelo LightGBM.

Figura 8. Importancia de variables S4, enfoque temporal mejor modelo LightGBM



Fuente: Elaboración propia a partir de datos procesados en Colab

Se observa que la incorporación de la Demanda Química de Oxígeno (DQO) y metales como el Cromo modifica la estructura de relevancia de las variables. En este caso, la DQO emerge como un descriptor fundamental, lo que indica que el modelo prioriza la carga orgánica compleja para refinar la estimación del ICA. Este hallazgo es relevante, ya que demuestra que, aunque las variables in situ proporcionan la base de la predicción, los parámetros de laboratorio aportan la capacidad adicional necesaria para capturar episodios de contaminación industrial que la conductividad por sí sola no logra discriminar.

Interpretación de predicciones de modelos usando SHAP

Las Figuras 9 y 10 presentan los diagramas de resumen (*Summary Plots*) de SHAP, que permiten interpretar la magnitud y la dirección de la contribución de cada parámetro en la predicción del ICA. El análisis se realizó sobre el conjunto de prueba bajo validación temporal utilizando LightGBM que obtuvieron el mejor desempeño en cada escenario y en S3 y S4, que son los escenarios parsimoniosos orientados a la optimización del monitoreo. Para escenarios S1 y S2

véase anexo 22. Es importante aclarar que SHAP se emplea únicamente con fines de interpretación y no para la selección de variables en la construcción de los escenarios.


En el escenario S3 (véase Figura 9), el valor medio absoluto de SHAP identifica a la Conductividad Eléctrica como el descriptor de mayor impacto sobre el modelo. Se observa una tendencia en la que valores altos de conductividad se asocian con contribuciones negativas (valores SHAP menores a cero), reduciendo el ICA predicho. Por el contrario, el Oxígeno Disuelto (OD) presenta un efecto positivo; concentraciones elevadas de OD se relacionan con contribuciones positivas, desplazando las predicciones hacia niveles superiores de calidad. Otros parámetros como la Turbidez y la Elevación también muestran influencia relevante; en particular, la elevación refleja la gradiente geográfica de la cuenca, asociando zonas de mayor altitud con aportes positivos al índice. El pH y la Temperatura exhiben distribuciones más concentradas alrededor de cero, lo que indica una influencia más localizada y estable.

En el escenario S4 (véase Figura 10), que incorpora metales pesados y la Demanda Química de Oxígeno (DQO), se conserva la relevancia de la Conductividad Eléctrica y el OD como principales factores, pero la DQO se incorpora como tercer descriptor clave según el valor medio absoluto de SHAP. Se observa que incrementos en la DQO tienden a generar contribuciones negativas, lo que permite al modelo identificar tramos con alta carga orgánica y vertimientos industriales. Los metales añadidos (Aluminio, Cromo y Cadmio) muestran impactos negativos consistentes en sus valores extremos, aunque con menor frecuencia de aparición. Esto sugiere que su inclusión aporta capacidad adicional para reconocer episodios de contaminación química. Bajo validación temporal, el desempeño global del modelo LightGBM mejoró de un R^2 promedio de 0.82 en S3 a 0.90 en S4, acompañado de una reducción del error en rangos bajos del ICA.

Finalmente, la comparación entre ambos escenarios mediante SHAP indica que las contribuciones de las variables son compatibles con expectativas físico-químicas: la conductividad y los metales se asocian con presiones negativas sobre la calidad del agua, mientras que el oxígeno disuelto se relaciona con aportes positivos, sugiriendo que la Conductividad Eléctrica y el DQO son variables críticas para explicar el ICA.


En consecuencia, se recomienda medir de forma obligatoria en todos los tramos del río la conductividad eléctrica, oxígeno disuelto, turbidez y DQO. En el contexto predictivo de estos escenarios, parámetros como, nitrato, hierro, zinc, níquel, fósforo y el caudal mostraron baja contribución marginal, y parámetros como el pH, temperatura, sulfato y metales traza mostraron baja influencia global en las predicciones. No obstante, la inclusión de metales (Aluminio, Cromo, Cadmio) en el escenario S4 mejoró la capacidad predictiva respecto a S3, lo que sugiere que su medición debe priorizarse en tramos críticos del río donde se espera mayor presencia de contaminantes metálicos. De esta manera, este esquema de monitoreo parsimonioso garantiza eficiencia analítica sin perder capacidad predictiva, y orienta la priorización de variables críticas en la gestión ambiental del río Bogotá.

Figura 9. SHAP variables S3, enfoque temporal mejor modelo LightGBM



Fuente: Elaboración propia a partir de datos procesados en Colab

Figura 10. SHAP variables S4, enfoque temporal mejor modelo LightGBM



Fuente: Elaboración propia a partir de datos procesados en Colab

8. DISCUSIÓN

La evaluación de los modelos de aprendizaje supervisado mostró un mejor desempeño de las arquitecturas basadas en LightGBM en comparación con baselines lineales (Elastic Net) y de kernel (SVR). Estos últimos presentaron limitaciones para capturar la complejidad no lineal de los parámetros del Río Bogotá, reflejándose en métricas de ajuste inferiores. Mientras que SVR tuvo dificultades para adaptarse a las fluctuaciones extremas de la calidad del agua, los modelos de ensamble lograron representar con mayor precisión la dependencia espacio-temporal. Los resultados completos de los cinco algoritmos evaluados (Elastic Net, Random Forest, XGBoost, LightGBM y SVR) se encuentran en los Anexos 14 y 18.

Un hallazgo relevante fue la transición del escenario S3 al S4. La integración estratégica de metales predominantes y la Demanda Química de Oxígeno DQO, permitió un incremento en el coeficiente de determinación. Bajo validación temporal, el R^2 promedio aumentó de 0.82 en S3 a 0.90 en S4. Este resultado coincide con lo reportado por Basha et al. (2024) en el río Shkumbini, donde DBO y HCO_3 aparecieron entre los principales determinantes del ICA. Sugiriendo que el monitoreo del Río Bogotá puede optimizarse al concentrar los recursos en variables sensorizadas in situ y en un conjunto selecto de parámetros de laboratorio, lo que representa un enfoque potencialmente más eficiente en términos técnicos y operativos.

No obstante, se reconoce como limitación la dependencia de la calidad y cantidad de la data histórica por punto de monitoreo. La reducida cantidad de observaciones en ciertas estaciones limita la capacidad de entrenamiento de los modelos, lo que subraya la necesidad de fortalecer las redes de captura de datos.

A pesar de estas limitaciones, la capacidad del modelo para asignar un peso significativo a la DQO y a los metales pesados en el escenario S4 respalda el uso de estas herramientas como apoyo en sistemas de vigilancia ambiental de bajo costo. En conjunto, los resultados sugieren que el río Bogotá presenta una “huella química” identificable, donde la aplicación de modelos de IA permite predecir el ICA con alta fidelidad y ofrece a las autoridades una ruta clara para modernizar la gestión del recurso hídrico sin comprometer la integridad de la información técnica. Si bien, los modelos lograron identificar episodios críticos de contaminación y asignar pesos significativos a variables como la DQO y los metales, estos resultados por sí solos no constituyen un sistema de alerta temprana. Para consolidar ese sistema se requiere integrar los modelos predictivos con sensores en tiempo real, protocolos de comunicación y sistemas de gestión de riesgo. En este estudio se demostró la viabilidad técnica de la predicción.

Se reportaron métricas puntuales de desempeño, estos resultados confirman la capacidad de generalización del modelo, pero dejan abierta la necesidad de una cuantificación de la incertidumbre, intervalos de confianza. Por ello, se propone como trabajo futuro la aplicación

esquemas de remuestreo temporal y espacial (cross-validation bloqueada, bootstrapping). Además, la aplicación de esquemas más exhaustivos como *rolling origin* o *leave-one-station-out* completo, con el fin de tener modelos que generalicen la cuenca; pues en este estudio se optó por escenarios fijos debido a la heterogeneidad y limitaciones de la base de datos.

Aunque se aplicó validación cruzada, en este estudio se reportaron únicamente los valores promedio de desempeño, no se cuantificó explícitamente la incertidumbre asociada, lo cual se reconoce como una limitación metodológica y se propone como trabajo futuro incorporar métricas de dispersión (media $\pm$ desviación estándar) para fortalecer la evaluación de la capacidad de generalización del modelo.

Con la importancia de variables mediante la reducción de impureza se midió la ganancia en entrenamiento basada en la estructura interna del modelo, mientras que con SHAP se analizó la contribución marginal en el set de prueba. Por ende, SHAP fue la métrica interpretativa principal y MDI fue complementaria.

9. CONCLUSIONES

- Mediante las técnicas exploratorias de PCA y análisis de correlación se identificaron fuertes interdependencias lineales entre ciertas variables de la base de datos. En particular, se evidenció redundancia entre sub-fracciones de nutrientes (nitrógeno amoniacal vs. nitrógeno total) y entre sub-fracciones de fósforo (reactivo vs. total), lo cual justificó la eliminación de estas variables sin pérdida de información significativa. Simultáneamente, se confirmó la independencia de las fracciones metálicas totales vs. biodisponibles, sugiriendo que algunas describen distintas dimensiones de la calidad del agua.
- A partir de lo anterior, se diseñaron escenarios con subconjuntos de predictores. El Escenario 2 (25 variables), resultante de la eliminación de 13 predictores redundantes o poco informativos (todas las fracciones biodisponibles de metales, las sub-fracciones de nutrientes y la variable temporal ‘año’), logró mantener el desempeño predictivo del modelo completo (Escenario 1 con 38 variables). Esto demuestra la viabilidad de un modelo más parsimonioso sin sacrificar precisión, lo que tiene implicaciones operativas en la reducción de costos de monitoreo.
- La comparación de arquitecturas de aprendizaje supervisado evidenció que los modelos basados en árboles en ensamble (en especial *LightGBM* y *XGBoost*) superaron ampliamente al modelo lineal regularizado (Elastic Net) y al modelo de kernel (SVR) en la predicción del ICA. *LightGBM* se consolidó como el algoritmo más consistente, alcanzando R^2 por encima de 0.90 en validación temporal y el algoritmo *random forest* con R^2 0.75 en la espacial; *XGBoost* obtuvo desempeños comparables e incluso fue el mejor en algunos escenarios (por ejemplo, mayor R^2 espacial en S1 y S2). En

contraste, SVR presentó mayor variabilidad y menor exactitud, mientras que Elastic Net (baseline lineal) no logró capturar las relaciones no lineales, obteniendo en validación espacial un $R^2 = 0.26$ en entrenamiento y en pruebas -0.188 , para la validación temporal en entrenamiento el R^2 fue de 0.1823 y en pruebas 0.553 , por lo que se confirma que la naturaleza no lineal del problema exige modelos más flexibles, y que el baseline lineal quedó relegado al rol de referencia teórica.

- La aplicación de SHAP permitió comprender la contribución de cada variable a la predicción del ICA, fortaleciendo la interpretabilidad del modelo final. En particular, se confirmó que variables como la conductividad eléctrica y el oxígeno disuelto ejercen la mayor influencia positiva en las predicciones (valores altos mejoran el ICA), mientras que otras como la turbidez, la DQO y los metales (Al, Cd, Cr) tienen impactos negativos: incrementos en estas se asocian con una degradación del índice. Estos hallazgos concuerdan con el conocimiento hidrológico (la conductividad es indicador de sales contaminantes; la DQO refleja carga orgánica; los metales pesados son tóxicos) y sirven para priorizar variables en programas de monitoreo.
- Los resultados evidencian una brecha clara entre la capacidad de generalización temporal y espacial. Mientras que los modelos lograron mantener un desempeño estable al extrapolar hacia años no observados (validación temporal), la generalización hacia la estación externa (validación espacial) resultó más limitada y con mayor variabilidad en las métricas. Es importante destacar que este comportamiento no representa necesariamente una deficiencia estructural de los algoritmos, sino que responde a un cambio de distribución (data shift) inherente a la estación de prueba (rca_bogota_cun_cota_pte.la virgen), la cual presenta un perfil de afectación hídrica severo y asimétrico (concentrado en las categorías Regular y Mala) respecto al promedio de la cuenca utilizado en la fase de entrenamiento. Así, la validación espacial funcionó como un escenario de estrés extremo para evaluar la robustez del marco predictivo ante condiciones críticas no balanceadas.
- En síntesis, esta investigación demostró que es posible estimar con alta precisión el ICA del río Bogotá usando un subconjunto optimizado de variables, mediante modelos de aprendizaje automático que preservan la interpretabilidad gracias a técnicas como SHAP. El marco propuesto respetó la dependencia espacio-temporal evitando sesgos por datos no independientes, y permitió alcanzar R^2 de 0.90 en validación temporal y 0.75 en la espacial con menos predictores que los esquemas tradicionales. Esto responde afirmativamente la pregunta de investigación, aportando una herramienta predictiva interpretable capaz de guiar la gestión ambiental en la cuenca del río Bogotá a través de la identificación de factores críticos (conductividad, OD, DQO, metales pesados) y la optimización de la red de monitoreo.

10. REFERENCIAS BIBLIOGRÁFICAS

- Aldrees, A., Khan, M. A., Tariq, M. A. U. R., Mustafa Mohamed, A., Ng, A. W. M., & Bakheit Taha, A. T. (2022). Prediction of water quality indexes with ensemble learners: Bagging and boosting. *Process Safety and Environmental Protection*, 168, 344-361. <https://doi.org/10.1016/j.psep.2022.10.005>
- Ahmad, Z., Alam, M. S., Alam, M. A., Awasthi, S., & Khan, M. A. (2024). AI powered water quality index prediction: Unveiling machine learning precision in hyper-arid regions. *Earth Systems and Environment*. <https://doi.org/10.1007/s41748-024-00524-8>
- Basha, L., Shyti, B., & Bektashi, L. (2024). Evaluating the performance of machine learning approaches in predicting Albanian Shkumbini Rivers waters using water quality index model. *Journal of Environmental Engineering and Landscape Management*, 32(1). <https://doi.org/10.3846/jeelm.2024.20979>
- Breiman, L. (2001). "Random Forests". *Machine Learning*, 45(1), 5-32. [Random Forests | Machine Learning | Springer Nature Link](#)
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. <https://dl.acm.org/doi/epdf/10.1145/2939672.2939785>
- Choudhary, K., Bohra, S., Sharma, P., & Sangal, A. L. (2025). Predicting water quality index using stacked ensemble regression and SHAP based explainable artificial intelligence. *Scientific Reports*, 15, Article 9463. <https://doi.org/10.1038/s41598-025-09463-4>
- Caicedo, A., & Pérez, L. (2021). Formulación de un índice de calidad de agua (ICA) a partir de parámetros fisicoquímicos. Estudio de caso: río Bogotá (periodo 2010-2020) [Trabajo de Grado, Universidad El Bosque]. Repositorio Institucional Universidad El Bosque. <https://repositorio.unbosque.edu.co/items/d4c926c9-a9d0-464c-8738-6c559ba698d6>
- Castañeda, J. S. (2020). Aplicación de técnicas de aprendizaje automático para la predicción de parámetros de calidad del agua: caso de estudio río. Repositorio Institucional Uniandes. <https://repositorio.uniandes.edu.co/entities/publication/f866f3e8-5d1c-42db-8342-4105bf5404ba>
- Corporación Autónoma Regional de Cundinamarca - CAR. (2020). Río Bogotá: Caracterización y Cuencas. https://www.car.gov.co/rio_bogota
- CAR. (2015). Estado del recurso hídrico en la cuenca del río Bogotá. <https://www.car.gov.co/uploads/files/5ade34bc6a1a9.pdf>

CAR. (2020). Prórroga de objetivos de calidad del río Bogotá.

<https://www.car.gov.co/uploads/files/5f872df1a93f6.pdf>

CAR. (2026). Autoridades frenan descargas contaminantes sobre el río Bogotá de una curtiembre en zona rural de Chocontá [Comunicado de prensa].

<https://www.car.gov.co/saladeprensa/autoridades-frenan-descargas-contaminantes-sobre-el-rio-bogota-de-una-curtiembre-en-zona-rural-de-choconta>

Cortes, C., & Vapnik, V. (1995). *Support-vector networks*. Machine Learning.

<https://link.springer.com/article/10.1007/BF00994018>

Ejaz, M., Zhao, W., Xu, H., Huang, Y., Yao, L., & Li, D. (2024). Integrated analytics and machine learning for water quality index assessment: Monitoring of industrial waste polluted stream. *Journal of Cleaner Production*, 451, Article 141877. <https://doi.org/10.1016/j.jclepro.2024.141877>

Elmotawakkil, A., Krimissa, S., Hachimi, C. E., Belghiti, M. E., Bouziani, M., & Nounah, A. (2025). Advanced machine learning models for robust prediction of water quality index and classification. *Journal of Hydroinformatics*, 27(2), 290-310.

<https://doi.org/10.2166/hydro.2025.290>

Géron, A. (2019). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems* (2a ed.). O'Reilly Media. <https://0-lucas.github.io/digital-garden/99.-Books/Hands-on-Machine-Learning.pdf>

Ho, J. Y., Afan, H. A., El-Shafie, A. H., Koting, S. B., Mohd, N. S., Jaafar, W. Z. B., ... & Elshorbagy, A. (2019). Towards a time and cost effective approach to water quality index class prediction. *Journal of Hydrology*, 575, 148-165.

<https://doi.org/10.1016/j.jhydrol.2019.05.016>

Hussein, E. E., Baloch, M. Y. J., Nigar, A., Abualkhair, H. F., Aldawood, F. K., & Tageldin, E. (2023). Machine Learning Algorithms for Predicting the Water Quality Index. *Water*, 15(20), 3540. <https://doi.org/10.3390/w15203540>

Hastie, T., Tibshirani, R., & Friedman, J. (2017). *The Elements of Statistical Learning*. <https://hastie.su.domains/ElemStatLearn/>

IDEAM. (2024). *Datos históricos de calidad del agua 2005–2024*.

<https://www.ideam.gov.co/nuestra-entidad/hidrologia/datos-calidad-del-agua-20052024>

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2023). An Introduction to Statistical Learning with Applications in R. <https://www.statlearning.com/>

Lawal, Z. K., Yassin, H., Lai, D. T. C., & Che Idris, A. (2024). Optimized ensemble methods for classifying imbalanced water quality index data. IEEE Access, 12, 171891-171908. <https://doi.org/10.1109/access.2024.3502361>

Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. <https://dl.acm.org/doi/10.5555/3295222.3295230>

Makumbura, R. K., Dissanayake, P. B. R., Rathnayake, N., Hoshino, Y., & Rathnayake, U. (2024). Advancing water quality assessment and prediction using machine learning models, coupled with explainable artificial intelligence (XAI) techniques like Shapley Additive Explanations (SHAP) for interpreting the black-box nature. Results in Engineering, 23, Article 102831. <https://doi.org/10.1016/j.rineng.2024.102831>

Nguyen, X. C., Nguyen, T. T. H., La, D. D., Kumar, G., Rene, E. R., Nguyen, D. D., Chang, S. W., Chung, W. J., & Nguyen, V. K. (2025). Robust water quality prediction across multiple indicator formulations using an explainable ensemble learning model. SSRN Electronic Journal. <https://doi.org/10.2139/ssrn.5318858>

Observatorio Ambiental de Bogotá. (2020, junio 9). Mejoró calidad del agua en un tramo del río Bogotá durante la cuarentena. Empresa de Acueducto y Alcantarillado de Bogotá. [Mejóro calidad del agua en un tramo del río Bogotá durante la cuarentena » Observatorio Ambiental de Bogotá](#)

Oliveira, M., Torgo, L., & Santos Costa, V. (2021). Evaluation Procedures for Forecasting with Spatiotemporal Data. Mathematics, MDPI. <https://www.mdpi.com/2227-7390/9/6/691>

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T. Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. https://proceedings.neurips.cc/paper_files/paper/2017/file/6449f44a102fde848669bdd9eb6b76fa-Paper.pdf

Ramya, S., Srinath, S., & Tuppad, P. (2024). Comprehensive analysis of multiple classifiers for enhanced river water quality monitoring with explainable AI. Case Studies in Chemical and Environmental Engineering, 10, Article 100822. <https://doi.org/10.1016/j.cscee.2024.100822>


- Shapley, L. S. (1952). A value for n-person games. RAND. [A Value for N-Person Games | RAND](#)
- Samuel, A. L. (1959). Some studies in machine learning using the game of checkers. IBM Journal of Research and Development, 210–229. <https://doi.org/10.1147/rd.33.0210>
- Sánchez Baldosea, A. (2025). modelo predictivo del riesgo en la calidad del agua para consumo humano en colombia. <https://repository.ucc.edu.co/entities/publication/206be534-427f-47c7-b1f6-5a092128322d>
- Semana Sostenible. (2021). Imponen medida de suspensión de vertimientos a curtiembre en Chocontá. <https://www.semana.com/sostenible/medio-ambiente/articulo/imponen-medida-de-suspension-de-vertimientos-a-curtiembre-en-choconta/202110/>
- Tziachris, P., Kallioras, A., & Voudouris, K. (2023). *Spatial or Random Cross-Validation? The Effect of Resampling Methods in Predicting Groundwater Salinity with Machine Learning*. Water. <https://www.mdpi.com/2073-4441/15/12/2278>
- Talukdar, S., Shahfahad, Bera, S., Naikoo, M. W., Ramana, G. V., Mallik, S., ... & Rahman, A. (2024). Optimisation and interpretation of machine and deep learning models for improved water quality management in Lake Loktak. Journal of Environmental Management, 345, Article 119866. <https://doi.org/10.1016/j.jenvman.2023.119866>
- Universidad de los Andes. (2004). Modelación dinámica de la calidad del agua del río Bogotá. <https://repositorio.uniandes.edu.co/entities/publication/89d16f69-3442-49a1-9391-847dbd499bf6>
- Chapman, D. (Ed.). (1996). Water Quality Assessments: A guide to the use of biota, sediments and water in environmental monitoring (2.^a ed.). UNESCO / WHO / UNEP. F&FN Spon. <https://iris.who.int/server/api/core/bitstreams/9ef98731-d51e-4692-9517-9bd6d76b9f38/content>
- Van Buuren, S. (2018). Flexible Imputation of Missing Data (2nd ed.). CRC Press. <https://stefvanbuuren.name/fimd/>
- Willmott, C (1982). Some Comments on the Evaluation of Model Performance. AMS. https://journals.ametsoc.org/view/journals/bams/63/11/1520-0477_1982_063_1309_scoteo_2_0_co_2.xml
- Zheng, H., Hou, S., Liu, J., Xiong, Y., & Wang, Y. (2024). Advanced Machine Learning and Water Quality Index (WQI) Assessment: Evaluating Groundwater Quality at the Yopurga Landfill. *Water*, 16(1). <https://www.mdpi.com/2073-4441/16/12/1666>

Zhong, S., Zhang, K., Wang, Z., Bagherzadeh, A., & Zhou, J. (2025). Climate responsive assessment of surface water quality in Songhua River using ensemble learning and multivariate analysis. *Journal of Water Process Engineering*, 70, Article 108342. <https://doi.org/10.1016/j.jwpe.2025.108342>


Zhou, J., Wang, Y., Xiao, F., Wang, Y., & Sun, L. (2022). A hybrid prediction framework for water quality with integrated W-ARIMA-GRU and LightGBM methods. *Water*, 14(9), Article 1322. <https://doi.org/10.3390/w14091322>

ANEXOS

Anexo 1. Matriz de Correlación de Pearson – Conjunto de datos completo




Anexo 2. Matriz de Correlación de Spearman - Data Escenario 4



La figura presenta la matriz triangular de correlaciones de Spearman entre los parámetros fisicoquímicos y metales pesados considerados en el Escenario 4, junto con el Índice de Calidad del Agua (ICA). Cada celda muestra el coeficiente de correlación, donde valores positivos (en verde) indican asociaciones directas y valores negativos (en rojo) reflejan relaciones inversas. Respecto al ICA, se evidencia que los principales tensores de degradación son la DQO, la Conductividad Eléctrica y la Turbidez, mientras que el Oxígeno Disuelto se consolida como el principal parámetro de recuperación hídrica.

Anexo 3. Distribución del ICA por punto de monitoreo



Se presentan diagramas de caja (boxplots) que resumen la distribución del Índice de Calidad del Agua (ICA) en cada estación de muestreo. La figura permite visualizar la variabilidad, valores atípicos y diferencias entre sitios, evidenciando la heterogeneidad espacial de la calidad del agua en la cuenca del río Bogotá.

Anexo 4. Resultados de la prueba de Shapiro-Wilk para las variables numéricas

Variable	W	p_value
ELEVACIÓN (m.s.n.m.)	0.6904	0.0
año	0.9176	0.0
mes	0.9497	0.0
ICA	0.9056	0.0
CAUDAL (l/s)	0.6548	0.0
NITROGENO TOTAL (mg/l)	0.8903	0.0
MANGANESO POTENCIALMENTE BIODISPONIBLE (mg mn/kg)	0.6536	0.0
NIQUEL POTENCIALMENTE BIODISPONIBLE (mg ni/kg)	0.8758	0.0
PLOMO POTENCIALMENTE BIODISPONIBLE (mg pb/kg)	0.3606	0.0
ALUMINIO POTENCIALMENTE BIODISPONIBLE (mg al/kg)	0.8443	0.0
COBRE POTENCIALMENTE BIODISPONIBLE (mg cu/kg)	0.3234	0.0
CROMO POTENCIALMENTE BIODISPONIBLE (mg cr/kg)	0.2976	0.0
HIERRO POTENCIALMENTE BIODISPONIBLE (mg fe/kg)	0.8667	0.0
CADMIO POTENCIALMENTE BIODISPONIBLE (mg cd/kg)	0.9329	0.0
ZINC POTENCIALMENTE BIODISPONIBLE (mg zn/kg)	0.5596	0.0
NITROGENO KJELDAHL TOTAL (mg n/l)	0.9139	0.0
ALUMINIO TOTAL EN AGUA (mg al/l)	0.7611	0.0
HIERRO TOTAL EN AGUA (mg fe/l)	0.8044	0.0
MANGANESO TOTAL EN AGUA (mg mn/l)	0.3982	0.0
FOSFORO TOTAL (mg p/l)	0.8949	0.0
DEMANDA BIOQUIMICA DE OXIGENO (DBO5) (mg o2/l)	0.8002	0.0
SULFATO (mg so4-2/l)	0.7512	0.0
CADMIO TOTAL EN AGUA (mg cd/l)	0.6962	0.0
PLOMO TOTAL EN AGUA (mg pb/l)	0.7042	0.0
CROMO TOTAL EN AGUA (mg cr/l)	0.5259	0.0
COBRE TOTAL EN AGUA (mg cu/l)	0.4580	0.0
NIQUEL TOTAL EN AGUA (mg ni/l)	0.6551	0.0
ZINC TOTAL EN AGUA (mg zn/l)	0.3889	0.0
NITROGENO AMONIAL (mg n-nh3-/l)	0.7856	0.0
NITRATO (mg n-no3-/l)	0.6265	0.0
NITRITO (mg n-no2-/l)	0.4286	0.0
TURBIDEZ (ntu)	0.4433	0.0
FOSFORO REACTIVO DISUELTO (mg p-po4-3/l)	0.7832	0.0
DEMANDA QUIMICA DE OXIGENO (DQO) (mg o2/l)	0.7974	0.0
OXIGENO DISUELTO (OD) (mg o2/l)	0.9323	0.0
SOLIDOS SUSPENDIDOS TOTALES (mg/l)	0.3402	0.0
CONDUCTIVIDAD ELECTRICA (µs/cm)	0.9553	0.0
pH (unidades de ph)	0.8963	0.0
TEMPERATURA (°c)	0.9788	0.0


La prueba se aplicó a cada variable considerando las 474 observaciones disponibles. En todos los casos se obtuvo $p < 0.05$, lo que indica que ninguna variable sigue una distribución normal. Aunque algunas variables como temperatura ($W=0.9788$) y conductividad eléctrica ($W=0.9553$) se aproximan visualmente a distribuciones normales, estadísticamente no cumplen el supuesto.

Anexo 1. Estadísticos descriptivos de los parámetros fisicoquímicos y metales

	mean	median	std	kurtosis	skew	CV
CROMO POTENCIALMENTE BIODISPONIBLE_(mg cr/kg)	41.136	13.900	233.084	388.315	18.975	5.666
MANGANESO TOTAL EN AGUA_(mg mn/l)	0.128	0.100	0.183	171.534	10.897	1.430
SOLIDOS SUSPENDIDOS TOTALES_(mg/l)	211.924	56.000	570.205	114.119	8.756	2.691
COBRE POTENCIALMENTE BIODISPONIBLE_(mg cu/kg)	7.347	5.465	13.907	73.139	7.920	1.893
ZINC TOTAL EN AGUA_(mg zn/l)	0.202	0.100	0.407	58.178	6.702	2.011
PLOMO POTENCIALMENTE BIODISPONIBLE_(mg pb/kg)	4.733	2.500	6.822	55.623	6.461	1.441
ZINC POTENCIALMENTE BIODISPONIBLE_(mg zn/kg)	72.435	51.200	85.353	55.511	6.007	1.178
NIQUEL TOTAL EN AGUA_(mg ni/l)	0.096	0.100	0.079	40.011	4.080	0.819
NITRATO_(mg n-no3-/l)	1.059	0.670	1.272	15.826	3.354	1.201
NITRITO_(mg n-no2-/l)	0.122	0.018	0.294	14.857	3.859	2.406
CAUDAL_(l/s)	31057.563	10784.000	46375.019	13.593	3.084	1.493
COBRE TOTAL EN AGUA_(mg cu/l)	0.086	0.045	0.122	12.000	3.532	1.424
DEMANDA QUIMICA DE OXIGENO (DQO)_(mg o2/l)	101.654	71.000	97.051	11.917	2.496	0.955
CADMIO TOTAL EN AGUA_(mg cd/l)	0.013	0.005	0.013	10.489	2.399	1.023
TURBIDEZ_(ntu)	589.955	52.500	1453.406	9.780	3.210	2.464
HIERRO TOTAL EN AGUA_(mg fe/l)	30.798	22.900	33.067	8.738	1.725	1.074
CROMO TOTAL EN AGUA_(mg cr/l)	0.379	0.045	0.762	7.144	2.763	2.009
pH_(unidades de ph)	7.218	7.155	0.610	6.389	1.496	0.085
ALUMINIO POTENCIALMENTE BIODISPONIBLE_(mg al/kg)	2165.867	1700.000	1469.328	4.641	1.785	0.678
SULFATO_(mg so4-2/l)	24.221	5.500	31.836	4.180	1.816	1.314
FOSFORO REACTIVO DISUELTO_(mg p-po4-3/l)	0.921	0.425	1.104	3.860	1.832	1.200
MANGANESO POTENCIALMENTE BIODISPONIBLE_(mg mn/kg)	254.979	163.500	277.808	3.268	2.111	1.090
HIERRO POTENCIALMENTE BIODISPONIBLE_(mg fe/kg)	10958.859	9896.000	7103.193	3.007	1.298	0.648
ALUMINIO TOTAL EN AGUA_(mg al/l)	22.284	23.900	26.354	1.515	1.455	1.183
NITROGENO AMONIACAL_(mg n-nh3-/l)	8.539	2.750	10.865	1.514	1.418	1.272
FOSFORO TOTAL_(mg p/l)	1.983	1.400	1.779	0.411	0.906	0.897
NITROGENO KJELDAHL TOTAL_(mg n/l)	16.584	16.000	14.223	0.236	0.789	0.858
TEMPERATURA_(°c)	19.202	18.450	4.394	-0.349	0.139	0.229
ICA	0.540	0.479	0.200	-0.581	0.750	0.370
CONDUCTIVIDAD ELECTRICA_(µs/cm)	381.993	396.000	244.800	-0.602	0.209	0.641
NITROGENO TOTAL_(mg/l)	18.529	14.200	16.684	-0.633	0.733	0.900
CADMIO POTENCIALMENTE BIODISPONIBLE_(mg cd/kg)	2.838	2.750	1.931	-0.876	0.359	0.680
NIQUEL POTENCIALMENTE BIODISPONIBLE_(mg ni/kg)	17.868	20.900	9.154	-1.053	-0.596	0.512
mes	7.076	7.000	3.088	-1.074	-0.161	0.436
DEMANDA BIOQUIMICA DE OXIGENO (DBO5)_(mg o2/l)	102.732	52.500	100.076	-1.230	0.671	0.974
OXIGENO DISUELTO (OD)_(mg o2/l)	3.592	3.600	2.454	-1.347	0.072	0.683

Se presenta medidas de tendencia central y dispersión (media, mediana, desviación estándar, asimetría, curtosis y coeficiente de variación) para cada variable del conjunto de datos, permitiendo caracterizar su comportamiento y variabilidad general.

Anexo 6. Distribución de parámetros fisicoquímicos y metales según estado del ICA




Se presentan diagramas de violín que muestran la distribución de variables fisicoquímicas (Temperatura, pH, Oxígeno Disuelto, Conductividad, Turbidez, DQO) y metales (Aluminio, Cadmio, Cromo) en relación con las categorías del estado del ICA (Buena, Regular, Aceptable, Mala y Muy Mala). La visualización permite identificar cómo varían las concentraciones de cada parámetro según la clasificación de calidad del agua.

Anexo 7. Cantidad de datos medidos en estaciones de monitoreo según clasificación del ICA

Estacion de Monitoreo	Aceptable	Buena	Mala	Muy Mala	Regular	Total Obs.
Bogota_Cun_Bogota_Cortijo El 37			13		1	14
Bogota_Cun_Chia_Frente Hacienda Darien			11		2	13
Bogota_Cun_Chia_Pte.El Comun	1		11		15	27
Rca_Bogota_Cun_Cota_Pte.La Virgen			28		28	56
El Colegio_Pte.Carretera La Mesa - Mesitas	2		24		22	48
Rca_Bogota_Cun_Girardot_Campina			52	3	3	58
Rca_Bogota_Cun_Soacha_Alicachin - El Salto			51	4	1	56
Rca_Bogota_Cun_Tocaima_Pte.Portillo			51		7	58
Cun_Tocancipa_Pte.Tulio Botero-Bogota	36	4			8	48
Rca_Bogota_Cun_Villapinzon_Pte.Carretera-Bogota	18	30				48
Rca_Bogota_Cun_Villapinzon_Sanpedro-Bogota	16	6	10	1	15	48

La tabla muestra el número de observaciones registradas en cada estación de monitoreo, clasificadas según el estado del ICA.

Anexo 8. Distribución de frecuencias y clasificación de la calidad del agua observada en la cuenca del río Bogotá según el ICA.



Esta gráfica presenta la distribución real de los datos históricos empleados en la modelación. Su valor metodológico radica en demostrar que el Río Bogotá posee una distribución bimodal (dos picos de densidad), fracturada en dos realidades ecológicas: un bloque crítico mayoritario en la categoría "Mala" (mediana de 0.48) y un segundo bloque menor de recuperación en las franjas "Aceptable" y "Buena".

Anexo 2. Listado de variables incluidas en cada escenario de modelado

N	Parámetro Incluido	S1	S2	S3	S4
1	Año	X			
2	Elevación (m.s.n.m.)	X	X	X	X
3	Mes	X	X	X	X
4	Caudal_(l/s)	X	X		
5	conductividad eléctrica_(μ s/cm)	X	X	X	X
6	demanda bioquímica de oxígeno (dbo5)_(mg o2/l)	X	X		
7	demanda química de oxígeno (dco)_(mg o2/l)	X	X		X
8	Oxígeno disuelto (od)_(mg o2/l)	X	X	X	X
9	ph_(unidades de ph)	X	X	X	X
10	solidos suspendidos totales_(mg/l)	X	X		
11	temperatura_(°c)	X	X	X	X
12	turbidez_(ntu)	X	X	X	X
13	aluminio total en agua_(mg al/l)	X	X		X
14	cadmio total en agua_(mg cd/l)	X	X		X
15	cromo total en agua_(mg cr/l)	X	X		X
16	cobre total en agua_(mg cu/l)	X	X		
17	fosforo reactivo disuelto_(mg p-po4-3/l)	X			
18	fosforo total_(mg p/l)	X	X		
19	hierro total en agua_(mg fe/l)	X	X		
20	manganeso total en agua_(mg mn/l)	X	X		
21	níquel total en agua_(mg ni/l)	X	X		
22	nitrato_(mg n-no3-/l)	X	X		
23	nitrito_(mg n-no2-/l)	X	X		
24	nitrogeno amoniacal_(mg n-nh3-/l)	X			
25	nitrogeno kjeldahl total_(mg n/l)	X	X		
26	Nitrogeno total_(mg/l)	X			
27	plomo total en agua_(mg pb/l)	X	X		
28	zinc total en agua_(mg zn/l)	X	X		
29	sulfato_(mg so4-2/l)	X	X		
30	aluminio potencialmente biodisponible_(mg al/kg)	X			
31	cadmio potencialmente biodisponible_(mg cd/kg)	X			
32	cobre potencialmente biodisponible_(mg cu/kg)	X			
33	Cromo potencialmente biodisponible_(mg cr/kg)	X			
34	hierro potencialmente biodisponible_(mg fe/kg)	X			
35	Manganeso Potencialmente biodisponible_(mg mn/kg)	X			
36	níquel potencialmente biodisponible_(mg ni/kg)	X			
37	plomo potencialmente biodisponible_(mg pb/kg)	X			
38	zinc potencialmente biodisponible_(mg zn/kg)	X			
TOTAL		38	25	7	11

Anexo 3. PCA - Contribución de variables a PC1–PC4 (Escenario 1)

	PC1	PC2	PC3	PC4	PC5	PC6
ELEVACIÓN (m.s.n.m.)	6.79	0.25	1.76	3.75	0.83	1.17
año	0.13	0.14	10.99	1.65	8.07	1.18
mes	0.04	0.11	1.03	1.97	1.44	0.09
CAUDAL_(l/s)	1.83	0.23	2.32	3.48	0.85	1.88
NITROGENO TOTAL_(mg/l)	7.37	0.14	1.35	4.44	1.01	1.23
MANGANESO POTENCIALMENTE BIODISPONIBLE_(mg mn/kg)	0.02	2.97	1.87	5.79	2.97	0.15
NIQUEL POTENCIALMENTE BIODISPONIBLE_(mg ni/kg)	2.07	7.47	0.30	7.40	0.36	0.31
PLOMO POTENCIALMENTE BIODISPONIBLE_(mg pb/kg)	0.74	4.46	7.31	0.04	12.89	2.07
ALUMINIO POTENCIALMENTE BIODISPONIBLE_(mg al/kg)	1.56	0.26	2.58	0.14	3.26	0.30
COBRE POTENCIALMENTE BIODISPONIBLE_(mg cu/kg)	0.46	3.21	8.08	0.45	15.88	2.08
CROMO POTENCIALMENTE BIODISPONIBLE_(mg cr/kg)	0.10	1.20	1.43	0.09	3.70	0.94
HIERRO POTENCIALMENTE BIODISPONIBLE_(mg fe/kg)	0.81	0.01	0.02	0.01	0.03	0.56
CADMIO POTENCIALMENTE BIODISPONIBLE_(mg cd/kg)	2.33	3.01	1.37	0.48	1.22	0.08
ZINC POTENCIALMENTE BIODISPONIBLE_(mg zn/kg)	0.54	0.06	11.26	0.36	11.30	7.03
NITROGENO KJELDAHL TOTAL_(mg n/l)	9.70	0.19	1.29	2.05	1.49	1.63
ALUMINIO TOTAL EN AGUA_(mg al/l)	0.20	10.33	1.72	3.62	1.32	2.92
HIERRO TOTAL EN AGUA_(mg fe/l)	0.90	13.33	2.47	0.35	3.29	1.77
MANGANESO TOTAL EN AGUA_(mg mn/l)	1.96	2.92	0.05	9.87	2.63	0.24
FOSFORO TOTAL_(mg p/l)	11.38	0.22	0.01	0.10	0.04	0.93
DEMANDA BIOQUIMICA DE OXIGENO (DBO5)_(mg o2/l)	0.14	3.85	5.29	1.25	0.39	0.99
SULFATO_(mg so4-2/l)	4.04	0.40	2.52	2.26	0.22	6.37
CADMIO TOTAL EN AGUA_(mg cd/l)	0.05	0.03	2.16	13.26	0.75	14.23
PLOMO TOTAL EN AGUA_(mg pb/l)	0.18	2.94	3.68	1.36	0.06	5.67
CROMO TOTAL EN AGUA_(mg cr/l)	0.05	6.01	2.84	0.69	1.15	0.31
COBRE TOTAL EN AGUA_(mg cu/l)	0.00	7.60	3.49	0.09	0.01	0.08
NIQUEL TOTAL EN AGUA_(mg ni/l)	0.05	8.49	0.40	5.61	3.70	9.84
ZINC TOTAL EN AGUA_(mg zn/l)	0.46	6.94	0.92	5.21	1.75	0.99
NITROGENO AMONIACAL_(mg n-nh3-/l)	7.98	2.49	0.10	0.63	0.27	5.59
NITRATO_(mg n-no3-/l)	0.25	2.05	4.69	0.00	5.28	3.42
NITRITO_(mg n-no2-/l)	0.05	1.61	2.95	0.00	5.89	4.66
TURBIDEZ_(ntu)	0.18	4.75	6.69	0.10	4.14	3.60
FOSFORO REACTIVO DISUELTO_(mg p-po4-3/l)	6.59	0.09	2.43	3.58	0.96	5.15
DEMANDA QUIMICA DE OXIGENO (DQO)_(mg o2/l)	7.91	0.08	0.47	0.85	0.00	0.01
OXIGENO DISUELTO (OD)_(mg o2/l)	1.93	0.01	2.85	2.61	0.38	0.26
SOLIDOS SUSPENDIDOS TOTALES_(mg/l)	1.98	0.77	0.13	12.03	0.03	9.43
CONDUCTIVIDAD ELECTRICA_(µs/cm)	10.48	0.49	0.79	0.30	0.94	0.27
pH_(unidades de ph)	1.50	0.50	0.04	2.63	0.43	1.13
TEMPERATURA_(°c)	7.26	0.35	0.33	1.49	1.10	1.44


La gráfica muestra los valores de carga de cada parámetro en las cuatro primeras componentes principales, del escenario 1, evidenciando patrones asociados a carga contaminante, mineralización y presencia de metales.

Anexo 4. PCA - Contribución de variables a PC1–PC4 (Escenario 2)

ELEVACIÓN (m.s.n.m.)	10.89	0.86	1.01	0.06
mes	0.26	0.18	4.95	0.02
CAUDAL_(l/s)	3.75	0.01	6.11	0.67
NITROGENO KJELDAHL TOTAL_(mg n/l)	10.17	0.10	9.07	0.12
NITRATO_(mg n-no3-/l)	0.48	4.17	8.63	0.46
NITRITO_(mg n-no2-/l)	0.14	2.92	7.13	0.03
ALUMINIO TOTAL EN AGUA_(mg al/l)	0.15	5.75	0.14	25.20
HIERRO TOTAL EN AGUA_(mg fe/l)	1.24	8.46	2.97	19.34
MANGANESO TOTAL EN AGUA_(mg mn/l)	4.21	4.33	9.56	0.26
FOSFORO TOTAL_(mg p/l)	13.23	0.35	0.84	0.01
DEMANDA BIOQUIMICA DE OXIGENO (DBO5)_(mg o2/l)	0.47	6.93	4.69	0.03
SULFATO_(mg so4-2/l)	7.42	1.51	1.19	0.61
CADMIO TOTAL EN AGUA_(mg cd/l)	0.00	2.02	3.77	32.70
PLOMO TOTAL EN AGUA_(mg pb/l)	0.24	6.89	0.15	11.76
CROMO TOTAL EN AGUA_(mg cr/l)	0.14	8.12	3.75	0.73
COBRE TOTAL EN AGUA_(mg cu/l)	0.01	12.12	0.29	0.42
NIQUEL TOTAL EN AGUA_(mg ni/l)	0.16	13.21	5.55	4.93
ZINC TOTAL EN AGUA_(mg zn/l)	1.08	11.36	3.72	0.07
TURBIDEZ_(ntu)	0.46	8.25	6.31	0.14
TEMPERATURA_(°c)	11.18	0.77	0.04	0.11
DEMANDA QUIMICA DE OXIGENO (DQO)_(mg o2/l)	11.04	0.00	0.19	0.40
OXIGENO DISUELTO (OD)_(mg o2/l)	1.94	0.04	8.36	0.00
SOLIDOS SUSPENDIDOS TOTALES_(mg/l)	5.72	0.95	5.97	0.02
CONDUCTIVIDAD ELECTRICA_(µs/cm)	12.46	0.33	5.60	0.44
pH_(unidades de ph)	3.18	0.39	0.02	1.47


La tabla muestra los valores de carga de cada parámetro en las cuatro primeras componentes principales, evidenciando qué variables aportan mayor peso a la estructura multivariada del escenario 2.

Anexo 5. Coeficientes parsimonia de Elastic Net, escenario S1, enfoque espacial



Este gráfico de la estructura espacial de Elastic Net evidencia el efecto de la regularización. Se observa claramente cómo las variables de la parte inferior fueron contraídas a cero de forma absoluta. Parámetros como los Sólidos Suspendidos Totales (SST) o los Nitratos, que teóricamente alteran la calidad del agua, se eliminaron debido a que el modelo lineal no pudo encontrar una relación directa y prefirió anularlos. Esto confirma empíricamente que la naturaleza del Río Bogotá es no lineal y que Elastic Net falló como selector automático y modelo baseline.

Anexo 6. Coeficientes parsimonia de Elastic Net, escenario S1, enfoque temporal




El gráfico de barras ilustra la magnitud y dirección de los coeficientes finales asignados por el algoritmo Elastic Net tras el proceso de optimización bajo la estructura de validación bloqueada temporal (Escenario 1). El eje vertical detalla los parámetros físico-químicos, microbiológicos y metálicos evaluados, mientras que el eje horizontal cuantifica la fuerza del coeficiente estandarizado, el algoritmo introduce inestabilidad estructural al asignar pesos negativos a fracciones metálicas específicas de manera aislada antes de su supresión. Este comportamiento sistemático de exclusión de descriptores hidroecológicos críticos confirma la inviabilidad de emplear selectores lineales automatizados para la depuración de la matriz hídrica del Río Bogotá, justificando la transición hacia arquitecturas no lineales basadas en ensambles.

Anexo 7. Métricas de desempeño comparativo - Modelos de aprendizaje supervisado (Escenarios S1-S4, validación espacial).

Escenario	Modelo	R ²	RMSE	MAE	RMSE relativo
S1	Elastic Net	-0.1876	0.0680	0.0552	13.44%
	Random Forest	0.8220	0.0263	0.0201	5.20%
	XGBoost	0.8504	0.0241	0.0172	4.77%
	LightGBM	0.9106	0.0187	0.0126	3.69%
	SVR	-0.9308	0.0867	0.0749	17.14%
S2	Elastic Net	-0.1993	0.0684	0.0551	13.51%
	Random Forest	0.8278	0.0259	0.0199	5.12%
	XGBoost	0.9308	0.0164	0.0128	3.24%
	LightGBM	0.9006	0.0197	0.0142	3.89%
	SVR	-0.8933	0.0859	0.0789	16.97%
S3	Elastic Net	0.1449	0.0577	0.0468	11.41%
	Random Forest	0.2112	0.0554	0.0445	10.96%
	XGBoost	0.1689	0.0569	0.0471	11.25%
	LightGBM	0.2491	0.0541	0.0425	10.69%
	SVR	0.513	0.044	0.0346	8.64%
S4	Elastic Net	-0.0556	0.0641	0.0529	12.67%
	Random Forest	0.7465	0.0314	0.0223	6.21%
	XGBoost	0.6577	0.0365	0.0271	7.22%
	LightGBM	0.6107	0.0390	0.0287	7.70%
	SVR	-0.3622	0.0729	0.0627	14.40%


La tabla resume los valores de R², RMSE, MAE y RMSE relativo obtenidos por cada algoritmo en los cuatro escenarios validación temporal, destacando en negrita el mejor desempeño por escenario según R².

Anexo 8. Curvas de Aprendizaje – Escenarios S2 y S4 (XGBoost y Random Forest)




Las gráficas muestran la evolución del error de entrenamiento y validación (RMSE) a medida que aumenta el tamaño del conjunto de entrenamiento, evidenciando la capacidad de generalización de los modelos en los escenarios espaciales S2 y S4 del mejor algoritmo.

Anexo 9. Reales vs. Predichos – Escenarios S2 y S4 (XGBoost y Random Forest)



Los gráficos comparan los valores observados y predichos del ICA en los escenarios espaciales S2 y S4, mostrando la precisión de los modelos frente a la línea ideal de ajuste.

Anexo 10. Residuos vs. Predichos – Escenarios S2 y S4 (XGBoost y Random Forest)




Los gráficos muestran la distribución de los residuos frente a los valores predichos del ICA, permitiendo evaluar el ajuste y posibles sesgos de los modelos en los escenarios espaciales S2 y S4.

Anexo 11. Métricas de desempeño comparativo - Modelos de aprendizaje supervisado (Escenarios S1-S4, validación Temporal).

Escenario	Modelo	R ²	RMSE	MAE	RMSE relativo
S1	Elastic Net	0.5532	0.1013	0.0765	20.78%
	Random Forest	0.9421	0.0365	0.0238	7.48%
	XGBoost	0.9717	0.0255	0.0163	5.23%
	LightGBM	0.9649	0.0284	0.0190	5.82%
	SVR	0.5315	0.1037	0.0784	21.28%
S2	Elastic Net	0.3942	0.1180	0.0774	24.20%
	Random Forest	0.9473	0.0348	0.0224	7.14%
	XGBoost	0.9727	0.0250	0.0165	5.13
	LightGBM	0.9734	0.0247	0.0173	5.07%
	SVR	-4.1020	0.3423	0.1060	70.23%
S3	Elastic Net	0.6976	0.0833	0.0673	17.10%
	Random Forest	0.8123	0.0656	0.0545	13.47%
	XGBoost	0.8095	0.0661	0.0502	13.57%
	LightGBM	0.8243	0.0635	0.0481	13.03%
	SVR	0.5700	0.0994	0.0636	20.39%
S4	Elastic Net	0.6833	0.0853	0.0701	16.85%
	Random Forest	0.8937	0.0494	0.0362	9.76%
	XGBoost	0.8574	0.0572	0.0468	11.31%
	LightGBM	0.9039	0.0470	0.0344	9.29%
	SVR	0.5610	0.1004	0.0631	19.84%


La tabla resume los valores de R², RMSE, MAE y RMSE relativo obtenidos por cada algoritmo en los cuatro escenarios, destacando en negrita el mejor desempeño por escenario según R².

Anexo 12. Curvas de Aprendizaje – Escenarios S2, S3 y S4 (LightGBM- mejor algoritmo)




Las gráficas muestran la evolución del error de entrenamiento y validación (RMSE) conforme aumenta el tamaño del conjunto de entrenamiento, ilustrando la capacidad de generalización del modelo LightGBM que fue el de mayor rendimiento comparado con los otros 4 algoritmos bajo validación temporal en los tres escenarios.

Anexo 13. Residuos vs. Predichos— Escenarios S2, S3 y S4 modelo (LightGBM)



Los gráficos muestran la distribución de los residuos frente a los valores predichos del ICA en los escenarios temporales S2, S3 y S4, permitiendo evaluar el ajuste y posibles sesgos del modelo LightGBM.


Anexo 14. Reales vs. Predichos – Escenario S2 (LightGBM)




El gráfico compara los valores observados y predichos del ICA bajo validación temporal en el escenario S2, mostrando la precisión del modelo LightGBM frente a la línea ideal de ajuste.

Anexo 15. SHAP variables S1 y S2, enfoque temporal mejores modelos

Variables S1 Modelo XGBoost



Variables S2 Modelo LightGBM



El *Summary Plot* basado en valores Shapley permite interpretar la magnitud y dirección del impacto de los parámetros físico-químicos y metales sobre la estimación del Índice de Calidad del Agua (ICA) mediante el algoritmo optimizado. A diferencia de las métricas de importancia tradicionales, este enfoque de IA explicable (XAI) discrimina cómo los valores altos o bajos de cada variable modifican positiva o negativamente el comportamiento del modelo.

Para S1 en validación temporal se puede ver que el modelo identifica que la Conductividad Eléctrica y los Sólidos Suspendidos Totales (SST) constituyen los dos ejes principales de varianza para la determinación del ICA. La conductividad exhibe una distribución donde los valores extremadamente altos (puntos azules dispersos a la derecha) generan un desplazamiento positivo en el output del modelo, actuando como el principal marcador de alteración iónica generalizada en la cuenca.

En S2, los valores SHAP se extienden desde -0.1 hasta más de 0.1. Al quitar el "ruido" de los metales biodisponibles (que en S1 comprimían el modelo acumulándose casi todos en el 0.0), el algoritmo LightGBM logra expandir la magnitud del impacto de los parámetros, promoviendo al Oxígeno Disuelto (OD) y a la Demanda Química de Oxígeno (DQO) en la jerarquía de contribución marginal, mientras que los SST se desplazan hacia la cuarta posición.

Disponibilidad de datos

Los datos estarán disponibles bajo solicitud.